

修士論文

介護マッチングサービスにおけるマッチング精度向
上の提案と実装

Proposal and Implementation for Improving Matching Accuracy in Elderly Care Matching
Services

北海道大学 大学院情報科学研究院
メディアネットワーク専攻 情報メディア環境学研究室

星子 祐哉

目次

第 1 章	序論	1
1.1	介護人材不足の量的課題	1
1.2	介護業界が直面する課題	3
1.3	介護マッチングアプリの仕組み	6
1.4	アーキテクチャとビジネスモデル	6
1.4.1	ビジネスモデル	6
1.4.2	現在のアプリのアーキテクチャ	6
1.5	現行マッチングシステムの限界	7
第 2 章	研究の目的	9
2.1	従来のマッチングシステムの限界	9
2.2	本研究のアプローチ	9
2.3	期待される効果	10
第 3 章	提案手法	11
3.1	自然言語処理モデルを利用した距離計算	11
3.1.1	ベクトル化とコサイン類似度	11
3.1.2	行列間の類似度計算	12
3.2	過去応募履歴の活用	12
3.2.1	ランキング生成（候補求人のスコアリング）	13
3.2.2	重み付けと拡張	13
第 4 章	実験	14
4.1	実験システムの実装とアーキテクチャ	14
4.1.1	システム概要	15
4.1.2	評価パイプライン	17
4.1.3	運用・拡張	18
4.2	予備実験 1：日本語 BERT モデルによる単語間類似度測定	20
4.3	予備実験 2：BERT モデルの横断評価	20
4.4	本実験 1：均等重みによる統合推薦	21

4.5	本実験 2：複数項目の重み付けによる精度向上	22
4.6	本実験 3：時間重み付け比較	26
4.7	本実験 4：時間重み自動選択の実装と結果	27
第 5 章	考察	30
第 6 章	ユーザースタディ	32
6.1	インタビュー対象者	32
6.2	求人選択の実態	32
6.3	情報収集の実態	33
6.4	ユーザースタディから得られた示唆	33
第 7 章	回避業務ペナルティと時間志向の実験	35
7.1	追加実験 1：回避業務ペナルティの検証	35
7.2	追加実験 2：時間志向を同時に扱った場合	39
第 8 章	今後の展望	43
第 9 章	結論	44
	謝辞	45
	参考文献	46
	研究業績	47
付録 A	重み付けパターン一覧（本実験 1～4）	48
付録 B	システム構成概要（ディレクトリベース）	50
付録 C	本実験 3：時間重み付け比較（特徴量配分別の詳細）	51
付録 D	基礎ベースライン（求人タイトルのみ・業務内容のみ）	54
D.1	求人タイトルのみ	54
D.2	業務内容のみ	55
付録 E	本実験 4 補足：時間重み自動判別の詳細結果	56

目次

1.1	介護職員数の推移と必要な増員ペース	2
1.2	介護福祉士資格保有者の内訳	2
1.3	人材確保のための 5 つの視点	3
1.4	介護事業者が直面する課題の構造	4
1.5	北海道における介護人材確保の特殊事情	5
1.6	介護特化型マッチングアプリの概要	6
1.7	システムアーキテクチャ概要（主要サービス間の疎結合構成）	7
1.8	現行マッチングシステムの定型条件フィルタリング構造	8
3.1	求人推薦スコア算出の全体フロー	12
4.1	推薦システム設計の全体像	14
4.2	技術スタックとディレクトリ構成	15
4.3	実験システムの Web GUI 画面例	16
4.4	BERT モデル別の分離度スコア	21
4.5	本実験 2 における主要パターンのスコア比較	25
7.1	18 名データの重み付けパターン比較（概観）	38
7.2	ペナルティ有無 + 時間重み自動判別の同時評価結果	41

表目次

4.1	予備実験 2 の評価データ（アンカーと類似/非類似職種の例）	20
4.2	均等重みにおける学習データ数別の精度推移	22
4.3	本実験 2 の主要重み付けパターン	23
4.4	本実験 2（20 件学習）の上位パターン	24
4.5	本実験 2（30 件学習）の上位パターン	24
4.6	学習データ数による精度推移（上位 5 件一致率、時間減衰なし）	25
4.7	時間重み付け比較（特徴量配分=equal, 複合スコア比較）	27
4.8	時間重み付け上位パターン（特徴量配分=equal, 学習 20 件）	27
4.9	ステップ別平均複合スコア（特徴量配分=equal, 有効ワーカー平均）	27
4.10	時間重み自動判別の実装結果（18 名, 平均 Top-K）	28
7.1	回避ペナルティ有無の平均精度（18 名, equal / 時間重み付け無し / 学習 20 件）	39
7.2	4 条件同時比較の平均精度（学習 20 件, 18 名, equal）	41
7.3	4 条件同時比較の平均精度（学習 15 件, 18 名, equal）	41
A.1	項目別重み付けパターン一覧（全体）	48
A.2	時間重み付けパターン（代表例）	49
A.3	時間重み付けパターン一覧（1/2）	49
A.4	時間重み付けパターン一覧（2/2）	49
C.1	時間重み付け比較（全特徴量配分平均, 複合スコア比較）	51
C.2	時間重み付け上位パターン（学習 20 件, 全特徴量配分）	51
C.3	時間重み付け上位パターン（学習 20 件, 全特徴量配分）	52
C.4	時間重み付け上位パターン（学習 30 件, 全特徴量配分）	53
D.1	ワーカー別の推薦精度（求人タイトルのみ, 30 件学習, 10 件テスト）	54
D.2	学習件数別の精度推移（求人タイトルのみ, 18 名）	54
D.3	就業回数上位 10 名を除いた場合の精度推移（求人タイトルのみ）	55
D.4	学習件数別の精度推移（業務内容のみ, 18 名）	55

D.5	就業回数上位 10 名を除いた場合の精度推移（業務内容のみ）	55
E.1	18 名データの時間パターン上位（学習 20 件, 平均 Top-K, 全重み付け平均）	56
E.2	20 名データにおける時間重み自動判別（equal）の学習ステップ別平均 Top-K（drift 閾値 0.5/0.7）	57
E.3	20 名データにおける時間重み自動判別（equal）の学習ステップ別平均 Top-K（drift 閾値 0.05）	57
E.4	20 名データにおける時間重み自動判別（equal）の学習ステップ別平均 Top-K（drift 閾値 0.03）	58

概要

近年、日本の介護業界は深刻な人材不足に直面している。厚生労働省の資料によると、2040 年までに約 69 万人の介護人材が不足する見込みである。一方で、有資格でありながら介護職に従事していない「潜在介護士」が約 37 万人存在し、供給可能な人材が十分に活用されていない。さらに、介護事業者は応募者が集まらないこと、採用コストの高騰、採用後の定着率の低さといった複合的な課題を抱えており、人材のミスマッチが常態化している。

本研究では、介護特化型マッチングアプリにおけるマッチング精度を向上させる手法を提案し、実装した。現状のマッチングシステムは「勤務地」「日程」「資格要件」などの定型条件の一致が中心であり、希望職種や過去の職務経験と求人内容の意味的な一致度は評価されていない。そのため、ワーカーと求人の潜在的な親和性が見逃されるおそれがある。

提案手法では、自然言語処理モデルを用いて距離を計算し、職種の距離（希望職種と実際の職種の一致度）とスキルの距離（職務経歴と求められるスキルの類似度）を測定する。また、時間的距離や勤務時間帯、過去の応募履歴などの要素を組み合わせる重み付けを行う。実験では、日本語 BERT モデルを含む複数の自然言語処理モデルを比較評価し、日本語 Sentence-BERT モデルが最も優れた分離度（0.398）を示すことを確認した。さらに、過去の求人応募データから新規求人との類似度を計算する手法を検証し、BERT による意味的類似検索の有効性を示した。

本研究により、介護マッチングサービスにおいて、ワーカーの希望により適合した求人を効率的に提示できるシステムの基盤を構築した。今後の課題として、実データを用いた検証、複数手法を組み合わせたより高精度なマッチングアルゴリズムの開発、実サービスへの実装とユーザーインタビューを通じた改善サイクルの確立が挙げられる。

第 1 章

序論

本研究は、介護特化型マッチングサービスにおけるマッチング精度の向上を目的とする。日本の介護業界は深刻な人材不足に直面しており、量的確保と質的マッチングの両面で構造的課題を抱えている。以下、厚生労働省の公式資料に基づき、現状の詳細な分析を行う。

1.1 介護人材不足の量的課題

介護人材不足の規模は極めて深刻である。図 1.1 に示すように、2022 年度の介護職員数は約 215 万人であるが、2026 年度には約 240 万人、2040 年度には約 272 万人が必要とされ、現在の増員ペース（年間約 1 万人）では必要な年間 6.3 万人に遠く及ばない状況にある [1]。この人材不足は、単なる労働力の絶対量の問題だけでなく、適切なマッチングが実現できていないという質的課題を同時に抱えている。

■潜在介護福祉士の存在と再就業障壁 介護福祉士国家資格保有者約 47 万人のうち、実際に福祉・介護分野に従事しているのは約 27 万人（約 57%）で、残り約 20 万人（約 43%）が「潜在介護福祉士」として未活用状態にある [2]。図 1.2 に示すように、資格保有者の半数近くが介護職に従事しておらず、この層を活用できれば年間 6.3 万人の 3 年分以上の不足をカバーできる可能性がある。

しかし、潜在介護福祉士の再就業を阻む障壁は多岐にわたる。主な要因として、（1）離職時の職場環境への不満が払拭されない不安、（2）ブランク期間による技術・知識の陳腐化への懸念、（3）家庭との両立が可能な柔軟な勤務条件を探す困難さ、（4）求人情報の不透明性（実際の業務内容や職場雰囲気が分からない）が挙げられる。特に、短時間・副業での復帰を希望する層にとって、従来の常勤中心の求人市場では適切な選択肢を見つけにくい。本研究で提案するマッチングシステムは、これらの障壁のうち特に（3）と（4）の解決に焦点を当て、柔軟な働き方と詳細な条件マッチングを実現することで、潜在層の再就業を促進する。

図1.1：介護職員数の推移と必要な増員ペース

需要増加に伴う需給ギャップの拡大と人材確保の緊急性




Page 02 | 介護人材マッチングシステム

2026-01-09 作成

図 1.1: 介護職員数の推移と必要な増員ペース

図1.2：介護福祉士資格保有者の内訳

資格保有者の半数近くが現場で活用されていない現状



Page 03 | 介護人材マッチングシステム

図 1.2: 介護福祉士資格保有者の内訳

■国の施策における位置づけ 厚生労働省は人材確保のための5つの視点の一つとして「潜在的有資格者等の掘り起こし」を明確に位置づけ、再就業促進を政策的に推進している[3]。図1.3に示すように、労働環境改善やキャリアパス確立と並んで、潜在介護福祉士の参入促進が重点施策として掲げられている。



図 1.3: 人材確保のための5つの視点

さらに、届出制度の整備も「介護福祉士の約6割しか介護職に従事しておらず、潜在介護福祉士活用のための方策が必要」との問題認識に基づいている[4]。しかし、制度面の整備だけでは不十分であり、実際に潜在層と事業者を効果的にマッチングする仕組みが求められている。

■総合的な人材確保戦略 介護人材確保の総合的取組では、参入促進・資質向上・労働環境改善の3つの柱が設定され、未経験者の参入促進と並行して潜在介護福祉士の再就業促進が推進されている[5]。このように、潜在介護福祉士の掘り起こしは国の重点施策として明確に位置づけられており、本研究で提案するマッチングシステムは、この政策目標の実現に直接貢献するものである。

1.2 介護業界が直面する課題

介護業界は以下に示す複合的かつ構造的な課題を抱えている。

■人材ミスマッチと経営危機 介護事業者は、応募者が集まらない、採用コストの高騰、採用後の定着率の低さといった複合的な課題に直面している。全国の介護事業所を対象とした調査によれば、約6割の事業所が「採用が困難」と回答しており、特に訪問介護事業所では7割を超える深刻な状況にある。採用単価は1人あたり平均30～50万円に達し、中小事業者にとって大きな経営負担となっている。

さらに深刻なのが定着率の低さである。介護職の離職率は約15%と全産業平均を上回

り、採用から1年以内の早期離職率は3～4割に達するとされる。この背景には、求人票の条件と実際の業務内容の乖離、職場環境への不適応、希望職種とのミスマッチなど、マッチング精度の問題が潜んでいる。例えば、「身体介護希望」で入職したワーカーが「生活援助中心」の現場に配置されるケースや、「日勤のみ希望」だったにもかかわらず夜勤を求められるケースなど、条件面のミスマッチが離職を誘発している。

人材のミスマッチが常態化した結果、サービスの質低下や廃業リスクの増大という深刻な経営課題を引き起こしている。採用単価30～50万円に対して、早期離職率が3～4割に達する場合、事業者は採用1人あたり実質90～125万円のコストを負担することになる（採用費×2.5～3人分）。年間10人採用する中小事業者では、年間約1,000万円の採用関連コストが発生する計算となり、これは介護報酬の低い業界構造においては極めて重い負担である。マッチング精度が10ポイント向上し、早期離職率が30%に抑制できれば、年間約200万円のコスト削減が可能となる。これらの問題は単なる人手不足だけでなく、ワーカーの希望・スキル・経験と求人内容の適切なマッチングが実現できていないことに起因する構造的な課題である。

図1.4：介護事業者が直面する課題の構造

高コスト・低定着率の悪循環とミスマッチの構造的要因



図 1.4: 介護事業者が直面する課題の構造

■**北海道の特殊事情** 本研究の対象地域である北海道は、全国平均と比較して極めて特殊かつ困難な条件下にある。図 1.5 に示すように、高齢化の進行と人口偏在が顕著であり、2025 年には高齢化率が約 33.5% に達すると予想される。これは全国平均（約 30%）を上回る水準である。

人口分布の偏りも深刻で、北海道の総人口約 520 万人のうち、約 3 分の 2 にあたる約 340 万人が札幌市とその周辺地域（石狩振興局管内）に集中している。残りの約 180 万人

が、本州の約 5 分の 1 にあたる広大な土地（約 78,000 平方キロメートル）に点在している。この結果、介護人材も札幌圏に集中し、地方部では深刻な人手不足が続いている。

地理的条件による課題も見逃せない。北海道の市町村間の平均距離は本州の 3～4 倍にのぼり、冬季には積雪・凍結により移動困難な期間が年間 4～5 ヶ月続く。例えば、旭川市から道北の稚内市までは約 250km、札幌市から道東の釧路市までは約 300km と、通勤圏としては現実的ではない距離である。このため、地方部の介護事業所は限られた地域内で人材を確保するしかなく、マッチングの選択肢が極端に狭まっている。

公共交通機関の脆弱さも大きな障壁となっている。札幌市以外の多くの地域では、バス路線の廃止・減便が進み、鉄道も廃線が相次いでいる。このため、自家用車を持たないワーカーは事業所への通勤が困難であり、高齢者の通所サービス送迎や訪問介護の移動時間も長大化している。ワーカーにとって「通勤可能な範囲」が狭く、事業者にとっても「応募可能な人材プール」が限定される悪循環が生じている。

さらに、若年層の道外流出も深刻である。高校・大学卒業を機に札幌圏または道外へ転出する割合が高く、地方部では介護人材の確保がますます困難になっている。これらの複合的な要因により、北海道、特に地方部における介護マッチングは、他都府県と比較して著しく高いハードルを抱えている。

図1.5：北海道における介護人材確保の特殊事情

広大な面積と厳しい気候条件がもたらす構造的なマッチング障壁



図 1.5: 北海道における介護人材確保の特殊事情

以上のように、介護業界は量的不足・経営負担・地域特性が絡み合う構造的課題を抱えている。そのため弊チームはこれらの課題に対して介護特化型マッチングアプリを開発・提供しているが、本研究ではそのマッチングアプリ内でのワーカーと求人の出会いを簡便化し、より少ない手間でマッチングできることを目指す。以下では、アプリの仕組みを示したうえで、現状のマッチング基盤が抱える限界を整理する。

1.3 介護マッチングアプリの仕組み

本研究で対象とする介護特化型マッチングアプリの概要を図 1.6 に示す。このシステムでは、介護事業者が求人情報を登録し、ワーカー（潜在介護士、副業希望者、その他就労希望者等）が希望の勤務地・時間・職種等を入力することで、システムが自動的にマッチングを行う。



図 1.6: 介護特化型マッチングアプリの概要

1.4 アーキテクチャとビジネスモデル

1.4.1 ビジネスモデル

本システムの事業モデルは、マッチング成立時の手数料収益と、事業者がワーカーへ直接アプローチするスカウト求人を主軸に構成する。手数料は採用・就業の実績に基づいて発生し、プラットフォームは成果連動で収益を得る。スカウト求人は、求職者の希望条件や過去の応募履歴に基づく個別提案として提供され、事業者側の採用スピードと成約率の向上を狙う。

1.4.2 現在のアプリのアーキテクチャ

本研究で利用したアプリは、マイクロサービスの疎結合アーキテクチャを採用し、スケーラビリティと保守性の両立を重視した設計としている。図 1.7 に全体構成を示す。

設計の主要な特徴は次の通りである。(1) **関心事の分離**: 事業者向け・ワーカー向け・管理者向けの各フロントエンドを独立開発可能とし、異なる技術スタック（Angular/Flutter）



図 1.7: システムアーキテクチャ概要（主要サービス間の疎結合構成）

を採用できる柔軟性を確保した。(2) **決済処理の分離**：金銭を扱う決済サービスを独立させることで、セキュリティ要件や会員データを局所化し、他サービスへの影響を最小化した。(3) **バッチ処理の独立性**：日次・月次の定期処理を cron-jobs として分離し、リアルタイム API サーバーへの負荷を回避した。(4) **統一的なデータベース**：複数サービス間でデータベースを共有し、データの一貫性を保ちつつ各サービスは必要なコレクションのみにアクセスする。この構成により、マッチングアルゴリズムの改善や自然言語処理モデルの追加といった機能拡張を、既存サービスへの影響を最小限に抑えながら実施できる。

1.5 現行マッチングシステムの限界

現行の介護マッチングシステムは、図 1.8 に示すように「勤務地」「日程」「資格要件」「介護種別」「給与範囲」などの定型条件によるフィルタリングが中心であり、実装としても以下の検索パラメータに限定されている：

- **地理的条件**: 都道府県・市区町村による完全一致フィルタ
- **時間的条件**: 勤務開始日・終了日による範囲検索
- **資格条件**: 介護福祉士、ヘルパー等の資格種別による完全一致
- **給与条件**: 日給の最低額・最高額による範囲検索
- **介護種別**: 訪問介護、施設介護等のカテゴリ一致

この設計には以下の構造的な問題が存在する。第一に、**希望職種と求人内容の意味的マッチングが欠如している**。例えば、ワーカーが「身体介護中心の業務」を希望していても、求人票に記載された職務内容のテキスト（「入浴介助」「移乗介助」等）との意味的な一致度は評価されない。第二に、**過去の応募・勤務履歴が活用されていない**。実際のワー

カー行動として、良い施設には繰り返し応募する「リピート志向」が観察されるが、ワーカーの手動の応募では以前の事業所に応募することは少々手間である。

第三に、**実質的な利便性要因が考慮されない**。後述するユーザーインタビューから、「駐車場の有無」等が重要な選択基準であることが判明した。交通費が往復 500 円の場合、駐車場がなければ地下鉄利用で実質赤字となるケースがあり、名目上の給与だけでは判断できない。しかし現システムでは、検索条件としてこのような交通の利便性を扱えない。第四に、**業務内容の詳細なマッチングが不可能**である。「入浴介助を避けたい」といった具体的な希望があっても、求人検索では「介護種別」という粗い分類でしか絞り込めない。

その結果、ワーカーは毎回多数の検索条件を手動で指定し、表示された求人リストから個別に内容を確認する必要がある。現行のスマートフォンアプリでは、条件指定のたびにサーバへの問い合わせが発生するため、検索体験の負荷が大きい。また、事業者側のスカウト機能も、同様の定型条件（対応可能地域、資格等）でのフィルタリングにとどまり、ワーカーとの潜在的な親和性は評価できていない。

図1.6：現行マッチングシステムの定型条件フィルタリング構造と限界

定型的な条件検索では捉えきれない「マッチングの質」の欠如



図 1.8: 現行マッチングシステムの定型条件フィルタリング構造

これらの課題を踏まえ、本研究では単純な定型条件マッチ（勤務地・日程・資格等）だけでなく、テキストの意味的類似性や履歴情報、時間的要因を組み合わせた重み付けにより、ワーカーと求人の潜在的親和性をより高精度に評価する手法を提案する。

第2章

研究の目的

本研究の目的は、現行システムの定型条件フィルタリングの限界を超え、**ワーカーと求人**の「**意味的・潜在的な親和性**」を多角的に捉えることで、双方の検索・推薦の手間を最小化し、マッチング精度を向上させることである。

具体的には、以下の3つの側面から改善を図る：

1. **意味的類似性の導入**：求人の記述テキストとワーカーの志向の**意味的な近さ**を導入し、従来の「介護種別」といった粗いカテゴリ分類を超えた精緻なマッチングを実現する。
2. **行動履歴の活用**：ワーカーの過去の応募・勤務履歴から志向性を推定し、明示的な条件指定に依存しない推薦を実現する。
3. **時間要因の考慮**：志向の変化や履歴の鮮度を反映し、古い履歴の影響を適切に制御する。

2.1 従来のマッチングシステムの限界

従来のマッチングシステムが抱える構造的課題（定型条件中心による意味的マッチングの欠如、履歴活用の不足、利便性要因の取り込み困難など）は、第1章1.5で述べた通りである。本章ではこれらの課題を前提として、以降で本研究の目的とアプローチを整理する。

2.2 本研究のアプローチ

本研究では、上記の課題に対して「意味的類似性」「履歴情報」「時間要因」を統合してスコアリングする方針を採用する。手法の具体化（類似度計算、履歴からの嗜好ベクトル、重み付けの統合）は第3章で述べ、評価は第4章以降で示す。

2.3 期待される効果

本研究により、以下の効果が期待される：

- **ワーカー側**：検索条件の入力が不要となり、過去の行動から自動的に適切な求人が推薦される。職種名や介護項目の表記ゆれに左右されにくくなり、気づいていなかった求人の提示も増える。リピート施設の発見が容易になり、勤務実績のある施設への応募がスムーズになる。さらに、条件調整にかかる時間が短縮され、新しい施設への応募ハードルが低減する。
- **事業者側**：適切なワーカーへの求人提示が自動化され、募集から応募までの導線が短縮される。求人の露出が「条件一致」に偏らず、業務内容や相性に基づいた候補に届くため、採用効率が向上する。ミスマッチによるキャンセルや早期離職が減少し、採用コストと現場負担の抑制が期待できる。
- **システム全体**：マッチング精度の向上により、プラットフォーム全体の取引量と満足度が向上する。ワーカーと事業者の双方が適切な相手を早期に見つけられるため、応募から就業までのサイクルが短くなる。結果として、継続的な利用や再応募が増え、サービスの信頼性と定着率の向上につながる。

これらのアプローチを通じて、介護業界における人材マッチングの効率化と、ワーカー・事業者双方の満足度向上を目指す。

第 3 章

提案手法

本研究では第 2 章で述べた方針に基づき、以下の要素を組み合わせた重み付けを提案する。

3.1 自然言語処理モデルを利用した距離計算

求人タイトルや業務内容、職務経歴などのテキストを自然言語処理モデルでベクトル化し、文書間の距離（類似度）を計算する。これにより職種の距離やスキルの距離を定量化できる。

3.1.1 ベクトル化とコサイン類似度

自然言語処理モデル（BERT 等）を用いて、テキストを高次元ベクトル空間に埋め込む。具体的には、求人タイトルや業務内容などの各テキストフィールドをモデルに入力し、固定長のベクトル表現を得る。

テキスト間の類似度評価には、ベクトル化された表現間のコサイン類似度を用いる。2 つのベクトル $\mathbf{a}$ と $\mathbf{b}$ のコサイン類似度は以下で定義される：

$$\cos(\theta) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{\sum_{i=1}^n a_i b_i}{\sqrt{\sum_{i=1}^n a_i^2} \sqrt{\sum_{i=1}^n b_i^2}}$$

ここで、 $\mathbf{a} = (a_1, a_2, \dots, a_n)$ および $\mathbf{b} = (b_1, b_2, \dots, b_n)$ は n 次元ベクトル、 $\mathbf{a} \cdot \mathbf{b}$ は内積、 $\|\mathbf{a}\|$ および $\|\mathbf{b}\|$ はそれぞれのベクトルのユークリッドノルムを表す。

コサイン類似度は $[-1, 1]$ の範囲の値を取り、1 に近いほど類似度が高く、0 は直交（無関係）、-1 は完全に反対の方向を示す。テキスト解析では通常、非負の値域 $[0, 1]$ で扱われる。

3.1.2 行列間の類似度計算

複数のテキストフィールド（例：求人タイトル、業務内容、介護項目など）を持つ文書全体の類似度を計算する場合、各フィールドをベクトル化した後、それらを行列として扱う。

文書 A のフィールドベクトルを $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m$ 、文書 B のフィールドベクトルを $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_m$ とする。このとき、行列間の類似度は以下の手順で計算される：

1. 各フィールドペア $(\mathbf{a}_i, \mathbf{b}_i)$ のコサイン類似度 s_i を計算
2. 各フィールドに重み w_i を付与し、加重平均を求める：

$$\text{Similarity}(A, B) = \frac{\sum_{i=1}^m w_i \cdot s_i}{\sum_{i=1}^m w_i}$$

この手法により、複数の観点から文書間の類似性を総合的に評価できる。重み w_i は実験的に調整され、本研究では7つの項目（求人タイトル、業務内容、介護項目、施設、勤務時間、時給、勤務日）に対して様々な重み付けパターンを検証した。

提案手法：求人推薦スコア算出の全体フロー

自然言語処理と構造化データを組み合わせたハイブリッド・マッチング



図 3.1: 求人推薦スコア算出の全体フロー

3.2 過去応募履歴の活用

本研究では、ワーカーの過去の応募・勤務履歴を用いて嗜好ベクトルを構成し、次に選ばれる求人を推定する。評価プロトコル（学習件数の変化、固定テストデータ、学習曲線）は第4章で述べる。

3.2.1 ランキング生成（候補求人のスコアリング）

学習区間に含まれる各求人を自然言語処理モデルでベクトル化し、履歴ベクトルの平均（必要に応じて時間重み・項目重みを適用）を嗜好ベクトルとする。テスト区間の各セッションに含まれる候補求人も同様にベクトル化し、嗜好ベクトルとのコサイン類似度によりランキングを作成する。

3.2.2 重み付けと拡張

嗜好ベクトルの構成では、複数項目の重み付けや履歴の新しさを反映する時間重み付けを同一の枠組みで扱える。また、回避傾向のある業務を含む求人にはペナルティを付与し、ランキングから外れやすくする拡張も可能である。具体的な設定と比較結果は第4章および第7章で示す。

第 4 章

実験

本節では、本研究で実施した予備実験および本実験の設計と結果を示す。

4.1 実験システムの実装とアーキテクチャ

実データ分析の実験環境は推薦モデル・評価器・データ処理・Web GUI を分離した多層構成として設計した。研究目的での再現性と拡張性を重視し、CLI/GUI のどちらからでも同一の評価パイプラインを呼び出せるようにした。推薦システム設計の全体像を図 4.1 に示す。



図 4.1: 推薦システム設計の全体像

4.1.1 システム概要

技術スタックとディレクトリ構成の対応関係を図 4.2 に示す。




図 4.2: 技術スタックとディレクトリ構成

また、実際の実験で利用した Web GUI 画面例を図 4.3 に示す。

技術スタック

- **Python:** 研究実装の中核言語。モデル推論・評価・可視化を一貫して実装。
- **PyTorch + Transformers:** Sentence-BERT によるテキスト埋め込みと類似度計算。
- **FastAPI + Uvicorn:** Web GUI/REST API を提供。非同期処理と並列実行に対応。
- **pandas / numpy / scikit-learn:** データ整形、集計、評価指標の算出。
- **外部データソース (任意):** 実データ取得時の補助的なデータソース (環境変数で有効化)。
- **Jinja2 / Static Files:** GUI テンプレートと静的資産を分離し、軽量な可視化を実現。
- **pymongo / python-dotenv:** 環境変数で本番 DB 連携を制御。

ディレクトリ構成と責務分離

- **推薦・評価:** Sentence-BERT ベースの推薦と評価機能。



図 4.3: 実験システムの Web GUI 画面例

- ・ **特徴量:** リピート志向、報酬、業務内容などの特徴量計算。
- ・ **ベースライン:** 職種のみ・介護項目のみ等の軽量手法。
- ・ **ユーティリティ:** データ読み込み、検証、可視化、設定管理。
- ・ **GUI/API:** Web GUI と API 層（テンプレートと静的ファイルを含む）。
- ・ **実行系:** 単一分析、バッチ分析、比較実験の実行機能。
- ・ **データ/結果/テスト:** 実データ、出力、テストを分離配置。

システムアーキテクチャ（層構造）

以下の層構造により、研究用のオフライン分析と対話的な評価を同一コードベースで実現している。

1. **データ層:** JSON/Markdown 形式のワーカーデータ、求人データを保持。

2. **前処理層**: セッション検証、テキスト正規化、特徴抽出を行う。
3. **モデル層**: Sentence-BERT による埋め込み生成と類似度計算。
4. **推薦ロジック層**: 重み付けパターン、履歴平均ベクトル、ベースライン手法の切替。
5. **評価層**: Top-K 等の指標算出と学習曲線評価。
6. **インタフェース層**: CLI 実行スクリプトと FastAPI Web GUI。

また、本システムは、**Web GUI/CLI** を入口として **評価パイプライン** を起動する構成である。GUI 層は FastAPI が担当し、ワーカー選択・実験条件（重み付けや特徴量モード）・進捗表示を提供する。GUI/CLI からの実行指示は評価層に渡され、**データ読み込み**（JSON/外部データ）→**前処理**→**特徴生成**→**推薦**→**評価**→**出力保存** の順に処理される。推薦層は「BERT ベース」「ベースライン」を切り替え可能で、同一インタフェース上で比較できる。出力層は JSON/テキスト/HTML に対応し、再現性の高い記録を残す。

4.1.2 評価パイプライン

データフロー（処理パイプライン）

1. データ読み込み：ワーカー履歴と求人リストを取得。
2. セッション検証：欠損や不正データを除外し、学習用・評価用に分割。
3. 特徴生成：求人テキスト（タイトル・業務内容・介護項目など）を統合しベクトル化。
4. スコアリング：平均ベクトルとのコサイン類似度、または特徴量スコアを計算。
5. 推薦生成：Top-K を抽出し、正解求人の順位を評価。
6. 出力保存：JSON/テキスト/HTML に結果と詳細ログを保存。

データモデル（主要フィールド）

実データはワーカー単位の履歴として保存され、セッションは「応募/勤務1回」を基本単位とする。評価では、各セッションに含まれるワーカーが選択した求人群とその時に提示されていた候補求人群を用いる。

- **ワーカー情報**: ワーカー ID (workerId)、氏名 (name)、資格 (qualifications) など。
- **セッション情報**: 勤務日 (workDate)、開始時刻 (startTime)、職種名 (jobTitle)、業務内容 (jobContent)。
- **求人情報**: 介護項目 (careItems)、施設名 (facilityName)、給与 (salary)、交通費 (transportationAllowance) など。
- **求人候補集合**: その時点で提示された求人候補群 (availableJobs)。

推薦アルゴリズム構成

- **Sentence-BERT ベース**: 求人タイトル・業務内容・介護項目・施設・勤務条件など複数項目の重み付けで統合類似度を算出。
- **項目別の重み付け比較**: 求人を構成する複数項目（職種名、業務内容、介護項目、施設、勤務条件など）の重み配分パターンを比較し、最適構成を探索。
- **時間重み付け比較**: 履歴の新しさ（直近重視・長期安定など）を反映する時間重みパターンを比較し、嗜好のドリフトに頑健な設定を探索。
- **ベースライン**: 職種のみ／介護項目のみで推薦する軽量モデルを実装し、BERT との差分を測定。
- **業務回避パターン**: 過去履歴から避けている業務を推定し、ペナルティを付与。ユーザースタディで得られた知見であるため、追加実験の章で詳述。

スコア統合の方針

BERT スコアは職種や業務内容の**意味的距離**を評価し、条件差分や履歴平均との差分との統合により総合スコアを構成する。利用頻度に応じて重みを動的に調整し、ライトユーザーとヘビーユーザーで推薦方針を切り替える設計としている。

評価設計

- **Top-K 精度**: Top-1/3/5 を基本指標とし、実務的推薦の再現性を評価。
- **複合スコア**: アプリでは最終的に**おすすめを 1 件**提示する想定であるため、Top-1 を重視した総合評価として、Top-1/3/5（それぞれ $T1, T3, T5$ ）を次式で 1 つの値に集約する（各 Top-K 精度は 0~1）。

$$S_{\text{composite}} = 0.5 \text{ Top-1} + 0.3 \text{ Top-3} + 0.2 \text{ Top-5}$$

と定義する（例：Top-1=39.0% は 0.390 として扱う）。

- **分割方法**: 段階的学習評価では、履歴の最初の **10 件を固定テストデータ**として、その後に続く履歴データを学習データとして k 件用意し、精度を算出する（ k を変化させて学習曲線を得る）。
- **学習曲線評価**: 学習件数を段階的に増やして性能変化を分析。

4.1.3 運用・拡張

高速化・キャッシュ戦略

- **事前エンコード**: 求人埋め込みを事前計算し、重み付け比較時の再計算を回避。
- **キャッシュ層**: メモリキャッシュとディスクキャッシュを併用し、再実験の時間を

短縮。

- **並列実行:** FastAPI 上で重み付けパターンを非同期で並列評価。
- **Apple Silicon 最適化:** MPS/スレッド設定を利用し高速化。

障害対策と再実行性

大規模バッチ実験では、途中失敗が研究コストに直結するため、**進捗ログと部分結果の保存**を重視した。GUI からの実行ではキャンセルフラグを監視し、エラー時は原因を JSON に記録して再実験を容易にする。

Web GUI と運用

- **FastAPI GUI:** ブラウザからワーカー選択・分析実行・進捗確認が可能。
- **API 連携:** JSON 形式で分析結果を取得でき、可視化・報告書作成に連携。
- **外部 DB 連携:** 実データ取得時に最新履歴を取得可能（環境変数による切替）。

API 設計の要点

GUI と同一のエンドポイントを API として公開し、分析の**自動化と外部連携**を可能にしている。単一ワーカー分析、バッチ分析、重み付け比較、事前エンコードといった操作が API 経由で呼び出せるため、研究プロセスの自動化に適する。

出力と再現性

- **結果出力:** JSON/CSV/テキストに加え、HTML レポートとして可視化。
- **ログ管理:** 実行ログ・進捗ログを保存し、追試可能な実験履歴を保持。
- **設定管理:** モデル名や評価パラメータを設定として集約。

拡張性

構成を**推薦エンジンの差し替えと特徴量の追加**に耐える設計とした。新規特徴量を追加して統合スコアに組み込むだけで再評価でき、新しい推薦モデルも同じ評価器に接続できる。

本章の構成

以上の実験環境と評価設計に基づき、以降では実験結果を段階的に示す。まず**予備実験 1・2**で、自然言語処理モデルの選定に関する基礎検証（単語間類似度の限界と、複数モデルの横断比較）を行う。続く**本実験 1**で複数項目統合（均等重み）の基礎性能、**本実験 2**で項目別重み付けの効果、**本実験 3**で時間重み付けの比較、**本実験 4**で時間重みの自動選択の検証へ進む。

4.2 予備実験 1：日本語 BERT モデルによる単語間類似度測定

自然言語処理モデルの代表例として BERT がある。本研究では日本語に特化した cl-tohoku モデルを利用し、単語間のコサイン類似度を計測した。しかし、「介護」と「極悪非道」の類似度が 0.678 であったり、「看護師」と「ナース」よりも「介護士」と「ナース」のほうが数値的に近かったりと、直感とずれる結果が得られた。この結果から、単一モデルに依存せず、横断的に複数モデルを検討する重要性が示された。

4.3 予備実験 2：BERT モデルの横断評価

予備実験 1 の結果を受け、単語レベルではなく**職種表現全体の意味**を捉えやすい埋め込み表現を前提に、複数の BERT 系モデルを横断的に比較した。評価指標として、アンカー職種に対して「類似職種の平均スコア」と「非類似職種の平均スコア」の差を取り、**分離度**として定義する。分離度が大きいほど、類似/非類似をより明確に区別できる。

評価データは、5 つのアンカー職種（店舗業務・IT・営業・医療・データ分析）ごとに「類似 4 件・非類似 4 件」を手動で作成した。語彙の近さだけでなく職域の近さがスコアに反映されるかを確認するため、非類似側には意図的に異業種の職種を含めた。

表 4.1: 予備実験 2 の評価データ（アンカーと類似/非類似職種の例）

アンカー	類似職種（例）	非類似職種（例）
レジ打ち	レジ係、キャッシャー	プログラマー、医師
プログラマー	ソフトウェアエンジニア、開発者	販売員、料理人
営業職	セールス、営業担当	経理、研究員
看護師	ナース、病棟看護師	デザイナー、建設作業員
データサイエンティスト	データアナリスト、ML エンジニア	警備員、調理師

比較対象は、BERT 系の **CLS** 埋め込みと平均プーリング、ならびに Sentence-BERT の日本語・多言語モデルである。いずれもコサイン類似度を用い、各アンカーの分離度を算出した後、アンカー平均をモデルの総合指標とした。

CLS・平均プーリング・Sentence 系の違い

BERT 系モデルは入力文をトークン列として処理し、各トークンに対応する埋め込みを出力するため、「文全体」を 1 本のベクトルにまとめる**プーリング**が必要になる。

- **CLS 埋め込み**: 文頭に付与される [CLS] トークンの最終層ベクトルを文表現とし

て用いる。分類タスク向けに設計された表現であり、短文や語順の揺れに対して文意が不安定になる場合がある。

- **平均プーリング (mean pooling)**：最終層のトークン埋め込み ([PAD] を除く) を平均し、文表現とする。文中の情報を広く集約できるため、短文の意味が安定しやすい。
- **Sentence-BERT (Sentence 系)**：Sentence-BERT のように**文同士の類似度が直接高くなるよう学習**（対照学習・ペア学習など）されたモデルであり、**コサイン類似度での近さが「文意の近さ」に対応しやすい**。

本研究では、これらの表現方式の違いが分離度に与える影響を確認した。




図 4.4: BERT モデル別の分離度スコア

図 4.4 より、日本語 Sentence-BERT が最も高い分離度を示し、マルチリンガル Sentence-BERT がそれに続いた。また BERT 系では、**平均プーリング**が **CLS** より安定して高い傾向が見られた。

以上の結果を踏まえ、以降の実験では分離度が最も高かった**日本語 Sentence-BERT**を標準モデルとして採用する。

4.4 本実験 1：均等重みによる統合推薦

本実験 1 では、求人タイトル、業務内容、介護項目、施設、勤務時間、時給、勤務日といった複数項目を統合し、**すべてを同一比率（均等重み）**で推薦スコアを構成した。現実の応募判断は「仕事内容が合うか」「条件が合うか」「施設が合うか」など複数の観点と同時に影響するため、まずはそれらを一つの枠組みにまとめたときの基準性能を確認する。本実験 1 は、項目ごとの重要度をまだ調整しない段階に位置づけられるため、以降の比較実験における出発点（基準条件）として機能する。

評価には 18 名分の実データを用いた。過去履歴のうち先頭から一定数を学習として用い、その直後の 10 件をテストとして逐次評価することで、学習件数を段階的に増やした場合の推移を測定した。精度指標としては、各テストで実際に選ばれた求人が推薦リスト

の上位 1 件/上位 3 件/上位 5 件に含まれるかを判定し、その一致率をワーカーごとに集計したうえで平均した。

表 4.2: 均等重みにおける学習データ数別の精度推移

学習件数	平均 Top-1	平均 Top-3	平均 Top-5	複合スコア
10	0.4500	0.5333	0.5833	0.5017
15	0.5167	0.6000	0.6778	0.5739
20	0.4778	0.6278	0.6944	0.5661
25	0.4200	0.5600	0.6333	0.5047
30	0.3091	0.4182	0.5273	0.3855
35	0.2727	0.4000	0.4818	0.3527
40	0.3250	0.4375	0.5500	0.4038

表 4.2 より、学習件数が増えるほど単調に改善するわけではなく、一定以上の履歴を取り込むと精度が低下する傾向が見られる。また、アプリでは最終的におすすめを 1 件提示する想定であるため、Top-1 を重視した総合評価として複合スコア ($0.5 \times \text{Top-1} + 0.3 \times \text{Top-3} + 0.2 \times \text{Top-5}$) も併記している。複合スコアは「上位に 1 件だけ出せばよい」という運用要件を反映しつつ、単発の一致・不一致に左右されやすい Top-1 だけに依存しないよう、上位 3 件・上位 5 件での一致も補助的に加味するための指標である。したがって、同じ Top-1 であっても Top-3/5 が高い条件は、実運用での候補提示の安定性が高いと解釈できる。この結果は、履歴を長く取るほど情報量が増える一方で、**過去の応募が必ずしも現在の関心を代表しない可能性を示している**。たとえば、働ける曜日や時間帯の変化、施設との相性、業務の得手不得手などにより、重視点が時間とともに移り変わる場合がある。そこで次の本実験 2 では、項目別の重み付けを変えることで、均等重みからの程度改善できるかを検証する。

4.5 本実験 2：複数項目の重み付けによる精度向上

本実験 1 では、複数項目を統合したとしても**均等重み**だけでは精度が頭打ちになり、学習件数を増やすと精度が低下する傾向も観察された。推薦においては、同じ求人でも「仕事内容が近いこと」を重視する人と「勤務条件が合うこと」を重視する人が存在し、**どの観点を強く反映すべきかはワーカーごとに異なる**と考えられる。本実験 2 ではこの点に着目し、**項目別の重み付け**を系統的に変化させることで、推薦精度にどの程度の差が生じるかを評価する。

具体的には、求人タイトル、業務内容、介護項目、施設、勤務時間、時給、勤務日など 7 項目について、相対的に強調する項目を変えた複数の配分を用意し、同一の評価手順で比較した。評価指標は、上位 1 件・上位 3 件・上位 5 件の一致率に加え、アプリでおすすめを 1 件提示する運用を踏まえ、上位 1 件を重視した**複合スコア** ($0.5 \times \text{Top-1} + 0.3 \times \text{Top-3} + 0.2 \times \text{Top-5}$) も用いる。ここでの目的は二つある。第一に、**項目重みの違いが精度差として現れるかを確認し**、重み付け設計が推薦性能に与える寄与を定量的に示すことである。第二に、本実験 1 で見られた「履歴を増やすと精度が落ちる」傾向が、重み付けを変

えることでどの程度緩和されるかを確認することである。

なお、重みの並びは「職種、業務内容、介護項目、施設、勤務時間、時給、勤務日」の順である。主要な配分は表 4.3 に示し、全一覧は付録 A に移した。表では、論文中の説明と見比べやすいように表示名を統一している。

表 4.3: 本実験 2 の主要重み付けパターン

表4.3 | 主要重み付けパターン

実験2で使用了各パターンの設計意図と重み配分（全7要素）

パターンID	GUI表示名	重み (7要素)	職種	業務	介護	施設	時間	時給	場所	意図
equal	均等	1 1 1 1 1 1 1	1	1	1	1	1	1	1	全項目を同一比率で扱う基準。
job_title_focused	職種重視	3 1 1 1 1 1 1	3	1	1	1	1	1	1	職種名の一致を重視。
content_focused	業務内容重視	1 3 1 1 1 1 1	1	3	1	1	1	1	1	業務内容の意味一致を強調。
care_focused	介護・施設重視	1 1 2 2 1 1 1	1	1	2	2	1	1	1	介護項目と施設種別を優先。
work_time_focused	勤務時間重視	1 1 1 1 3 1 1	1	1	1	1	3	1	1	勤務時間の条件一致を強調。
salary_focused	時給重視	1 1 1 1 1 3 1	1	1	1	1	1	3	1	報酬条件を優先。
content_salary	業務内容 × 時給	1 3 1 1 1 3 1	1	3	1	1	1	3	1	業務内容と報酬を同時に強化。
salary_time_strong	時給 × 勤務時間強化	1 1 1 1 4 4 1	1	1	1	1	4	4	1	条件重視をさらに強化。
comprehensive	総合重視	1 3 2 2 2 3 1	1	3	2	2	2	3	1	内容・介護・条件を幅広く強化。

まず、学習 18 件の結果（表 4.3 および図表出力）を見ると、均等配分に加えて、業務内容や介護項目、勤務条件を相対的に重視した配分が上位に現れた。これは、単一の観点到偏るよりも、仕事内容と条件の両面をある程度取り込むことが、集団平均としては有利に働く可能性を示している。一方で、学習 30 件の結果（表 4.6 および上位パターン表）では、全体として精度が低下し、順位も入れ替わる。これは本実験 1 と同様に、履歴を長く取り込むことで古い嗜好や一時的な選好が混入し、現在の関心から外れていく影響が残っていることを示唆する。

図 4.5 は、主要な配分におけるスコアの違いを可視化したものである。項目の強調の仕方により推薦順位が変化し、結果として一致率に差が生じることが分かる。ただし、その差は常に大きいわけではなく、複数の配分がほぼ同程度のスコアを示す区間も存在する。このため、集団平均だけを見ると配分間の差が僅差になりやすく、最適配分を一つに決め切ることは必ずしも容易ではない。実際には、ワーカーごとに当たりやすい配分が異なり、ある配分で改善するワーカーがいる一方で別の配分では悪化するワーカーがいるなど、個人差が平均の中で相殺されうる。したがって、単一の配分を全員に固定するよりも、後段の検証（本実験 3 以降）で扱うような履歴の新しさや個別差を考慮する工夫が重要に

表 4.4: 本実験 2（20 件学習）の上位パターン

表4.4 本実験2（20件学習）の上位パターン					
Top-1/3/5精度および複合スコアによるランキンガー一覧					
※ 複合スコア降順					
順位	パターン名	Top-1	Top-3	Top-5	複合スコア
1	均等	57.1%	70.6%	77.1%	0.7112
2	介護・施設重視	58.2%	68.2%	77.6%	0.7094
3	勤務時間重視	52.9%	68.2%	77.1%	0.6959
4	時給 × 勤務時間強化	54.1%	69.4%	75.9%	0.6959
5	時給重視	51.8%	69.4%	76.5%	0.6941
6	勤務条件重視	55.3%	67.7%	75.9%	0.6929
7	極度時給重視	52.9%	65.3%	74.7%	0.6753
8	高バランス	49.4%	65.3%	74.1%	0.6653
9	業務内容 × 時給	51.8%	62.9%	74.1%	0.6629
10	職種重視	55.3%	67.1%	70.0%	0.6618


表 4.5: 本実験 2（30 件学習）の上位パターン

表4.5 実験2（30件学習）の上位パターン					
順位	パターン名	Top-1	Top-3	Top-5	複合スコア
1	総合重視 comprehensive	30.0%	56.0%	63.0%	0.5430
2	時給×勤務時間強化 salary_time_strong	38.0%	49.0%	63.0%	0.5380
3	業務×介護×時給 content_care_salary	32.0%	52.0%	61.0%	0.5250
4	職種重視 job_title_focused	38.0%	51.0%	59.0%	0.5240
5	実務重視 practical_focused	26.0%	55.0%	60.0%	0.5170
6	業務内容×時給 content_salary	37.0%	50.0%	57.0%	0.5090
7	高バランス balanced_high	33.0%	54.0%	56.0%	0.5080
8	介護・施設重視 care_facility_focused	37.0%	47.0%	57.0%	0.5000
9	超強力業務内容 super_strong_content	35.0%	48.0%	57.0%	0.4990
10	均等 equal	34.0%	50.0%	56.0%	0.4980

なる。

また、表 4.6 は、学習件数を変化させた場合の精度推移（上位 5 件一致率）をまとめたものである。重み付けパターンにより絶対的な精度には差が出る一方で、一定の学習件数までは上がり、その後は低下するという全体傾向は本実験 1（均等重み）と概ね同じであった。このことから、項目別重み付けは「どの観点を強調すればよいか」を改善できる一方で、「古い履歴をどの程度参照すべきか」という時間的な問題は残ると考えられる。したがって次の本実験 3 では、履歴の**新しさ**を直接扱う時間重み付けを導入し、この傾向を緩和できるかを検証する。

表 4.6: 学習データ数による精度推移（上位 5 件一致率、時間減衰なし）



順位	パターン	複合スコア	TOP-5	TOP-5 STD	TOP-3	TOP-3 STD	TOP-1	TOP-1 STD
1	均等 (equal) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:1, 時給:1, 勤務日:1	0.7112	0.7706	0.2114	0.7059	0.2249	0.5706	0.2494
2	介護・施設重視 (care_focused) 求人タイトル:1, 業務内容:1, 介護項目:2, 施設:2, 勤務時間:1, 時給:1, 勤務日:1	0.7094	0.7765	0.1855	0.6824	0.2351	0.5824	0.2481
3	勤務時間重視 (work_time_focused) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:3, 時給:1, 勤務日:1	0.6959	0.7706	0.2201	0.6824	0.2378	0.5294	0.2733
4	時給×勤務時間強化 (salary_time_strong) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:4, 時給:4, 勤務日:1	0.6959	0.7588	0.1938	0.6941	0.1919	0.5412	0.3104
5	時給重視 (salary_focused) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:1, 時給:3, 勤務日:1	0.6941	0.7647	0.2029	0.6941	0.2358	0.5176	0.2856
6	勤務条件重視 (conditions_focused) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:3, 時給:3, 勤務日:1	0.6929	0.7588	0.2063	0.6765	0.2306	0.5529	0.2809
7	極度時給重視 (extreme_salary) 求人タイトル:1, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:1, 時給:5, 勤務日:1	0.6753	0.7471	0.2478	0.6529	0.2764	0.5294	0.3274
8	高バランス型 (balanced_high) 求人タイトル:2, 業務内容:2, 介護項目:1, 施設:1, 勤務時間:1, 時給:2, 勤務日:1	0.6653	0.7412	0.1770	0.6529	0.2649	0.4941	0.2989
9	業務内容×時給 (content_salary) 求人タイトル:1, 業務内容:3, 介護項目:1, 施設:1, 勤務時間:1, 時給:3, 勤務日:1	0.6629	0.7412	0.2033	0.6294	0.2592	0.5176	0.3226
10	求人タイトル重視 (job_title_focused) 求人タイトル:3, 業務内容:1, 介護項目:1, 施設:1, 勤務時間:1, 時給:1, 勤務日:1	0.6618	0.7000	0.2236	0.6706	0.2469	0.5529	0.2896

図 4.5: 本実験 2 における主要パターンのスコア比較

4.6 本実験 3：時間重み付け比較

本実験 1・2 では、重み付けにより精度差は生じるものの、学習件数が増えると精度が低下する傾向が共通して観察された。これは、古い履歴が現在の嗜好から外れていく影響が無視できないことを示唆する。そこで本実験 3 では、**履歴の新しさを評価に反映する時間重み付け**を導入し、この傾向を緩和できるかを検証する。

具体的には、過去履歴の寄与に対して、直近ほど大きな重みを与える減衰関数（指数・線形・ウィンドウ・セッション順など）を比較する。本実験 3 では本文の議論を明確にするため、特徴量配分を**均等（equal）**に固定し、時間重み付けの効果に焦点を当てる。他の特徴量配分を含む詳細な結果は付録 C にまとめた。以降の結果は、**学習ステップ 20（履歴 20 件）**を主に用い、学習ステップ別の推移は表 4.9 に示す。

主要な時間重み付けの代表例は付録 A に移し、本文では要点のみを整理する。

- **時間減衰なし**：全履歴を同一の重みで参照する基準。
- **指数減衰**：履歴が新しいほど重く、古いほど急速に軽くする。最近の応募・閲覧に強く引っ張られるため、嗜好が短期間で変わるユーザーに対して追従しやすい。一方で、過去の安定した好みを反映しにくくなる場合がある。
- **線形減衰**：履歴の新しさに応じて重みを一定の割合で段階的に小さくする。指数減衰よりも「古い履歴もある程度は残す」形になりやすく、短期と長期のバランスを取りたい場合に適する。
- **期間制限型**：一定期間内の履歴だけを参照し、それ以前は参照しない。古い履歴の混入を確実に防げるため、嗜好の変化や季節要因の影響を受けやすい場合に有効である。
- **セッション順の減衰**：日付ではなく行動の順序で「新しさ」を定義し、直近ほど重くする。タイムスタンプの精度が十分でない場合でも、相対的な新旧を用いて最近の行動を優先できる。

18 名データでは、特徴量配分を equal に固定した場合でも、**直近重視の指数減衰**が複合スコア=0.6339（Top-1=0.5556, Top-3=0.6944, Top-5=0.7389）で最良となった。**直近 30 日線形減衰**は複合スコア=0.6139（Top-1=0.5333, Top-3=0.6722, Top-5=0.7278）、**時間減衰なし**は複合スコア=0.5661（Top-1=0.4778, Top-3=0.6278, Top-5=0.6944）であり、最良パターンは時間減衰なしに比べて +0.0678 の改善となる。短期の履歴を強く反映する設計が、集団平均では安定して有利であることが確認できる。なお、表 4.9 は複合スコアのステップ別推移（有効ワーカー平均）である。

本実験 3 の結果から、集団平均では短期志向の時間重みが優位である一方、ワーカーごとに最適な時間重みが異なることも示唆された。そこで次に、個別差を考慮して短期/長期の志向を自動判別し、適切な時間重みを切り替える手法を検証する。

表 4.7: 時間重み付け比較（特徴量配分=equal, 複合スコア比較）

代表パターン	複合スコア	平均 Top-1	平均 Top-3	平均 Top-5	備考
直近重視の指数減衰	0.6339	0.5556	0.6944	0.7389	最良
直近 30 日線形減衰	0.6139	0.5333	0.6722	0.7278	線形に直近を重視
時間減衰なし	0.5661	0.4778	0.6278	0.6944	ベースライン

表 4.8: 時間重み付け上位パターン（特徴量配分=equal, 学習 20 件）

順位	時間重み	複合スコア	平均 Top-1	平均 Top-3	平均 Top-5
1	直近 7 日指数減衰	0.6339	0.5556	0.6944	0.7389
2	Softmax 7 日	0.6272	0.5556	0.6833	0.7222
3	セッション順線形 10 件	0.6172	0.5389	0.6667	0.7389
4	直近 30 日線形減衰	0.6139	0.5333	0.6722	0.7278
5	直近 30 日指数減衰	0.6117	0.5389	0.6556	0.7278

表 4.9: ステップ別平均複合スコア（特徴量配分=equal, 有効ワーカー平均）

学習ステップ	時間減衰なし	直近 30 日線形減衰	直近 7 日指数減衰
5	0.5989	0.6100	0.6167
10	0.5017	0.5056	0.4872
15	0.5739	0.6167	0.5933
20	0.5661	0.6139	0.6339
25	0.5047	0.5380	0.5127
30	0.3855	0.5009	0.4991
35	0.3527	0.4573	0.4764
40	0.4038	0.3825	0.3763

4.7 本実験 4：時間重み自動選択の実装と結果

本実験 4 では、履歴の変化量（drift）に応じて時間重み付け方式を切り替える仕組み（時間重み自動判別）を実装し、固定方式（時間減衰なし・直近 30 日線形減衰）と比較する。

基本方針

直近の履歴と過去の履歴がどの程度乖離しているかを定量化し、乖離が大きい場合は短期追従（直近重視の指数減衰）、乖離が小さい場合は長期安定（期間制限型）を採用する。本研究の履歴には日付が付与されているため、「短期追従」は直近重視の指数減衰（例：直近 7 日指数減衰）で実装し、「長期安定」は期間制限型（例：直近 90 日ウィンドウ）で実装する。

ドリフトの算出

自動選択の核は、直近と過去の差分を数値化することである。本研究ではこの差分を drift（ドリフト）と呼ぶ。

算出手順は次の通りである。

1. 各履歴（求人テキスト）を Sentence-BERT で埋め込みベクトルに変換する。

2. 履歴を「直近の数件」と「それ以前」に分割する（直近側は最小 2 件・最大 5 件、かつ履歴長の $1/3$ を上限）。
3. それぞれの平均ベクトルを計算する（直近： $\mathbf{v}_{\text{recent}}$ 、過去： $\mathbf{v}_{\text{past}}$ ）。
4. 両者の類似度をコサイン類似度 $s = \cos(\mathbf{v}_{\text{recent}}, \mathbf{v}_{\text{past}})$ で計算する（ s が大きいほど類似）。

そして

$$\text{drift} = 1 - s$$

と定義する。したがって、**drift が大きいほど直近と過去の乖離が大きい**ことを意味する。

切替規則

- drift が小さい（0.12 未満）：嗜好は安定しているとみなし、**期間制限型**（例：直近 90 日ウィンドウ）を用いる。
- drift が大きい（0.12 以上）：嗜好が変化しているとみなし、**直近重視の指数減衰**（例：直近 7 日指数減衰）を用いる。

このように、状況に応じて長期安定と短期追従を切り替える。

実装上は、判定結果（採用方式、drift 値、直近ウィンドウ長）をワーカー単位にキャッシュし、同一履歴長での再計算を省略することで、繰り返し評価における計算コストを抑えた。

評価設定と結果

検証は 18 名データで実施し、特徴量配分は**均等 (equal)**に固定した。学習ステップ 20（履歴 20 件）を用い、時間重みだけを変えて平均 Top-K を比較した結果を表 4.10 に示す。

結果として、時間重み自動判別は**時間減衰なし**より改善した一方で、固定方式である**直近 30 日線形減衰**のほうが高い値を示した。また、自動判別は閾値（0.12）や最近ウィンドウの取り方によって挙動が変わるため、**今後は閾値や候補パターンの見直し**でさらに改善する余地がある。

表 4.10: 時間重み自動判別の実装結果（18 名, 平均 Top-K）

時間重み	平均 Top-1	平均 Top-3	平均 Top-5
時間減衰なし	0.4778	0.6278	0.6944
時間重み自動判別	0.4944	0.6500	0.7056
直近 30 日線形減衰	0.5333	0.6722	0.7278

18 名データにおける時間志向の分布

時間重み自動判別の判定結果から、18 名データの時間志向を集計した。**短期志向が 3 名（16.7%）、長期志向が 15 名（83.3%）**であり、長期志向のワーカーが多数を占めた。

これは、対象期間において大半のワーカーの履歴が「直近と過去で大きく乖離していない」ことを示す。一方で短期志向に分類されたワーカーは drift が相対的に大きく、直近行動の重視が有効になりやすい。実運用では、季節要因や生活状況の変化（勤務可能時間の変化、施設との相性、希望職種の変化など）により志向が急変するケースも考えられるため、**短期志向の検出**は個別最適化において重要な役割を担う。

時間パターン別の詳細な比較結果（18 名データ）と、20 名データを用いた drift 閾値の追試結果は付録 E に示す。

第 5 章

考察

本研究の実験結果から導かれる主要な考察を以下に示す。

- **利用頻度による精度差：**多く働いているユーザー（データが豊富なユーザー）とそうでないユーザーで応募傾向が大きく異なる。頻繁に利用するユーザーはシンプルな予測でも高い精度であったのに対し、利用頻度が低いユーザーでは予測がほとんどできなかった。これはユーザーの利用頻度に応じた重み付け調整の必要性を示唆する。
- **最適学習データ量：**学習データ量については、15 件～20 件程度が最適帯であることが判明した。20 件学習時の最高複合スコアは 0.7112（均等パターン）であるのに対し、30 件学習時は 0.5273 まで低下する。これは約 18% の精度低下に相当する。過度に過去のデータを学習すると、古い嗜好が現在の嗜好を汚染し精度が低下するためと考えられる。したがって、時間的な重み付け（古いデータを低減する等）を導入することが有効である。
- **重み付けパターンの選択：**20 件学習では「均等 (equal)」パターンが最良であったが、30 件学習では「総合重視 (comprehensive)」が最良となる。これは学習データ量によって最適な重み付けが変化することを示しており、動的な重み調整が望ましい。
- **時間重み付けの有効性（実験 3）：**時間重み付けでは、均等重みよりも直近重視の減衰が上位に現れ、特に線形減衰や指数・パワー減衰が安定して高い Top-5 を示した。これは「古い履歴の影響を下げる」ことが精度に寄与することを示唆する。一方で、日付ベース/セッションベースのどちらが優位かはデータ特性に依存し、短期の行動変化が強いワーカーでは急峻な減衰が有効、長期で安定した志向では緩やかな減衰が適する可能性がある。
- **時間重み自動選択の位置づけ（実験 4）：**自動判別は均等重みを上回る結果を示し、ドリフトが大きいワーカーに対する追従性を高める効果が確認された。しかし、半減期 7 日での指数減衰が最良であった点から、自動選択は万能ではなく、drift の

しきい値のさらなる実験と調整が必要である。

したがって、ユーザーの利用頻度に基づく重み付け、時間的重み付け（直近 15～20 件を重視、線形/指数減衰の併用）、および自動判別の併用を検討することが望ましい。学習データ量と重み付けの最適帯が存在する点を踏まえ、ワーカー単位での動的な調整を前提とした運用設計が重要である。

ただし、これらの知見はあくまで応募履歴にもとづくオフライン評価であり、実際のサービス利用場面での論点は、精度指標だけでは十分に捉えられない。そこで次章では、介護ワーカーへのインタビューを通じて求人選択の実態を整理し、推薦に求められる情報や現在のサービスの課題を明らかにする。

第 6 章

ユーザースタディ

第 5 章で得られた知見は、推薦精度 (Top- k や複合スコア) という観点では有効性を示した。一方でさらなる精度の改善にはユーザー視点の確認が不可欠である。

そこで本章では、介護ワーカーの求人選択の実態と、推薦表示に求められる情報を把握するためにユーザースタディを実施した。候補者はカスタマーサービスと連携して 40 名へインタビューの依頼を行った。現段階では 30 分程度のインタビューを 2 件実施している。

6.1 インタビュー対象者

1 件目のインタビュー対象者は、介護経験 7 年目のワーカーで、現在は副業としてマッチングサービスを月 4~5 回程度利用している。過去に 4 つの事業所での勤務経験があり、サービスの活用方法について豊富な知見を持つ。

2 件目のインタビュー対象者は、実務者研修時に当アプリを知り、母親の利用をきっかけに単発バイトとして利用を開始した。複数のサービス機能を実際に利用しており、システムの使い勝手について具体的なフィードバックを提供した。

6.2 求人選択の実態

インタビューから、ワーカーの求人選択プロセスには明確な優先順位があることが判明した。

■**リピート志向の強さ** ワーカーは一度良いと感じた施設には繰り返し応募する傾向が非常に強い。「いつも行くところがあれば、そこを選ぶ」という発言から、リピート施設が第一選択肢となっており、新規施設の探索は「いつもの施設が空いていない場合」に限られることが分かった。この背景には、「お互いゼロから教えなくていい」という相互の効率性への配慮がある。

■**駐車場の重要性** 予想外に高い重要度を示したのが「駐車場の有無」である。交通費が往復 500 円で、地下鉄の往復料金を超えると赤字になるため、駐車場がない施設は敬遠される。これは時給以上に意思決定に影響する要因であることが示された。

■**業務内容の選好** 特定の業務（入浴介助等）の有無は、時給よりも優先される場合がある。「入浴がない」ことが施設選択の重要な条件となっており、業務内容の詳細表示が求人者の魅力度に直結することが確認された。

■**給与の基準** 給与については「8 時間勤務、1 時間休憩、交通費込みで 1 万円程度」が望ましい水準として挙げられた。時給換算よりも「1 回でがつつり稼ぎたい」という総額志向が見られた。

6.3 情報収集の実態

新規施設を選ぶ際、ワーカーは以下の手順で情報を収集していた：

1. 近い場所から順に閲覧
2. 業務内容と口コミを確認
3. 知人からの横のつながりで得た情報を参照

特に「当マッチングアプリを使っている友達」からの情報共有が活発であり、「ここはヤバかった」といった具体的な評判が意思決定に強く影響することが判明した。

6.4 ユーザースタディから得られた示唆

- **リピート行動の重要性**：ワーカーは一度良いと感じた施設に繰り返し応募する傾向が非常に強い。「いつもの施設」が第一選択肢となり、新規施設の探索は限定的である。これは本実験 1 で観察された「多く働いているユーザーは特定の求人者に繰り返し応募する」という傾向と一致しており、過去の応募履歴による推薦の有効性を裏付ける。
- **非テキスト要因の影響**：駐車場の有無や特定業務（入浴介助等）の可否が、時給以上に意思決定に影響することが示された。これらの構造化データは「勤務条件」として扱われるが、さらに細分化して高い重みを与える必要がある。特に駐車場は往復交通費が赤字になる閾値（500 円）との関係で重視される。
- **総額志向**：給与については時給換算よりも「1 回でがつつり稼ぎたい」という総額志向が見られた。時給だけでなく、1 回あたりの想定総収入も併記すると判断材料になりやすい。
- **口コミと横のつながり**：知人からの情報共有が活発であり、「ここはヤバかった」と

いった具体的な評判が意思決定に強く影響する。これは本研究のスコアリングモデルには含まれていない要素であり、今後は評価スコアやレビューデータの統合が課題となる。

- **フィードバックの心理的効果**：利用後に「役に立てた実感」が得られる仕組みは内発的動機付けを高め、継続利用につながる可能性が示された。
- **初回訪問時の情報非対称性**：単発マッチングにおける最大の課題は、初回訪問時の情報格差である。事前情報提供の充実が応募ハードルを下げ、マッチング成功率を向上させる可能性がある。

ユーザースタディでは、入浴介助などの特定業務が「時給よりも優先される回避条件」になり得ることが分かった。つまり、推薦の上位に**避けたい業務を含む求人**が並ぶと、表示はされても応募に結びつかず、推薦の実用性が下がってしまう。

そこで次章（第7章）では、この「避けたい業務の存在」を推薦スコアに反映するため、回避業務を含む求人を**減点して再ランキングする回避業務ペナルティ**を提案する。回避業務の推定方法、ペナルティ係数の設計、そしてペナルティ有無の比較実験により効果を整理する。

第 7 章

回避業務ペナルティと時間志向の実験

ユーザスタディでは、「入浴介助など、特定の業務はできれば避けたい」という声が複数確認された。これは、推薦が「文章の似ている求人」や「条件の合う求人」を上位に並べるだけでは、**ワーカーが応募しにくい要因**を十分に扱えていない可能性を示唆する。

本章では、この「避けたい業務」を推薦結果に反映するために、**回避業務ペナルティ**を導入し、再ランキング（並べ替え）として実装・評価した。回避業務ペナルティとは、ワーカーが**あまり選ばない（応募しにくい）業務**を「回避項目」として推定し、その回避項目を含む求人の推薦スコアを減点して順位を下げる仕組みである。

本章の目的は二つある。第一に、回避業務ペナルティを単体で適用したときに、推薦上位の質（Top- K 精度）が改善するかを確認する（追加実験 1）。第二に、履歴の新しさを考慮する**時間重み自動判別**と同時に適用したときに、両者が競合せずに補完的に働くかを確認する（追加実験 2）。

7.1 追加実験 1：回避業務ペナルティの検証

目的と設計方針

追加実験 1 の目的は、回避業務ペナルティを「実装可能な形」に落とし込み、推薦順位がどの程度改善するかを定量的に示すことである。本章で扱うのは、求人本文を自然言語処理モデルで解釈して回避業務を推定する方法ではなく、求人に付与された**介護項目タグ**に基づいて減点する方法である。

タグに基づく方式を採用する理由は次の通りである。

- **計算が軽い**：埋め込み計算や追加推論を増やさずに減点できる。
- **説明可能性が高い**：「この求人は**入浴介助**が含まれるため順位が下がった」のように理由を示しやすい。

- **UI と相性が良い**：注意喚起やフィルタの設計に接続しやすい。

用語の定義（セッション）

本章では、アプリが求人候補のリストを提示し、その中からワーカーが最終的に 1 件を選ぶ（応募する）までを **1 回のセッション**と定義する。推薦の評価は、このセッションを単位として行い、「そのセッションで実際に選ばれた求人が、推薦上位に入るか」を確認する。

全体の流れ

追加実験 1 は、各ワーカーについて次の流れで実行した。

1. セッションごとに、(A) 候補として提示された求人のリストと、(B) 実際に選ばれた求人を取得する。
2. 求人に付与された介護項目タグを用いて、タグごとの**選択率**を算出し、選択率が低いタグを回避項目として確定する（回避の強さも数値として保存する）。
3. 既存の推薦モデル（Sentence-BERT 等）で各候補求人に推薦スコアを付ける。
4. 回避項目を含む求人は、回避項目の多さ／強さに応じてスコアを減点し、スコア順に再ランキングする。
5. ペナルティ無し／有りで、Top-1/Top-3/Top-5 の精度を比較する。

回避業務が指す具体項目（介護項目タグ）

本章でいう「回避業務」は、求人に付与されている介護項目タグ（文字列の集合）を指す。本研究で扱ったデータには、**入浴介助、排泄介助、食事介助、移動介助、起床・就寝介助、着脱介助、口腔ケア、体位変換、バイタル測定、介護記録、配膳下膳、レクリエーション、清掃、リネン交換**などが含まれる。

また、求人によっては**夜勤**や**送迎**といった勤務形態・付帯業務が同じ枠組みで付与されており、これらも回避対象になりうる。**該当なし**は当該求人で介護項目が付与されていない（または明示されていない）ことを表すラベルとして現れる。

回避項目の推定（タグの選択率）

回避業務ペナルティを適用するには、まず「どのタグを避けたい傾向があるか」を、ワーカーの過去の選択（応募）履歴から推定する必要がある。本章では、タグごとの**選択率**を用いて回避項目を定義する。

各セッションでは、(A) 提示された候補求人のリストと、(B) 実際に選ばれた求人が観測できる。直観的には、あるタグが候補側にしばしば登場するにもかかわらず、選択側ではほとんど登場しない場合、そのタグは「避けられている」可能性が高い。

そこで、タグ t に対して次を定義する。

- $\text{cand}(t)$ ：候補側でタグ t が 1 回でも出現したセッション数
- $\text{chosen}(t)$ ：選択側（実際に選ばれた求人）にタグ t が含まれていたセッション数

そして

$$\text{select_rate}(t) = \frac{\text{chosen}(t)}{\text{cand}(t)}$$

を選択率とする。 $\text{select_rate}(t)$ が低いほど、候補には出るが選ばれにくいことを意味する。

本章では、 $\text{select_rate}(t) < 0.30$ のタグを回避項目と判定し、回避度合い（回避スコア）を

$$\text{avoid_score}(t) = 1 - \text{select_rate}(t)$$

として保存する。閾値 0.30 は実装の初期値として採用した経験則であり、ワーカー数やデータ量が増えた段階で再調整する余地がある。

集計単位（候補側はセッション単位）

候補側の出現回数を求人件数ではなくセッション数で数えるのは、「同じセッションで候補が大量に表示された」ことによる偏りを抑えるためである。例えば、あるセッションで候補が 30 件あり「入浴介助」タグ付き求人が 10 件含まれていても、候補側では「入浴介助が出たセッション」として +1 だけ数える。別のセッションで候補が 5 件で、入浴介助が 1 件だけ含まれていても同様に +1 である。

このように候補側をセッション単位で数えることで、候補数が多いセッションに引きずられにくく、より素直な「選ばれやすさ／避けられやすさ」として回避傾向を推定できる。

ペナルティ係数の計算（減点の設計）

回避項目が含まれる求人に対して、回避の「含まれやすさ」と「強さ」に基づいて減点を適用する。本章では、求人ごとに次の 2 つの量を用意する。

- r ：その求人に付いているタグのうち、回避項目が占める割合
- $s_{\max}$ ：その求人に含まれる回避項目のうち、最大の回避スコア

ここで $s_{\max}$ は「その求人に含まれる回避項目の中で、いちばん回避が強い項目の回避スコア」である。つまり、その求人に回避項目が複数含まれる場合でも、最も強い 1 つを代表として取り出し、その値を $s_{\max}$ とする。例えば、ある求人に回避項目が 2 つ含まれ、それぞれの回避スコアが 0.8（強く避けたい）と 0.3（やや避けたい）であれば、より大きい 0.8 を採用するため、 $s_{\max}$ は 0.8 となる。

$s_{\max}$ を用いる意図は、回避項目の中には「1 つ含まれるだけで応募意欲が大きく下がる」ものがありうるためである。最大の回避スコアを参照することで、回避スコアが特に

高い項目（いわばボトルネック）を強く反映できる。一方で、回避項目が含まれない求人では、実装上は $s_{\max} = 0$ と扱い、 $r = 0$ と合わせてペナルティが発生しない。そして、ペナルティ重みを $w = 0.5$ として、係数（0～1）を

$$\text{penalty_factor} = (1 - r \cdot w) \times (1 - s_{\max} \cdot w)$$

で計算し、推薦スコアに掛ける。これにより、(i) 回避項目が多い求人、(ii) 回避が強い項目を含む求人ほど、より強く順位が下がる。

例として、ある求人に 4 個のタグが付いており、そのうち 2 個が回避項目なら $r = 2/4 = 0.5$ である。また、最大回避スコアが $s_{\max} = 0.8$ のとき

$$\text{penalty_factor} = (1 - 0.5 \times 0.5) \times (1 - 0.8 \times 0.5) = 0.75 \times 0.6 = 0.45$$

となる。元の推薦スコアが 1.0 なら、ペナルティ適用後は 0.45 となり、上位に出にくくなる。

適用タイミング（再ランキング）

実装上は、本実験中で行ったような方式で候補求人に一度スコアを付けたあとで、各候補の `penalty_factor` を掛けてスコアを更新し、**点数の高い順に並べ直す**ことでペナルティを反映する。また、ペナルティを受けた求人については「どの回避項目が含まれていたか（`avoided_items_in_job`）」を付随情報として保持し、結果画面で理由を追えるようにしている。

結果

18 名データを対象に、**特徴量配分は equal、時間重み付け無し**の設定で平均精度を算出した。学習件数は**学習ステップ 20（履歴 20 件）**とし、回避ペナルティ**無しと有り**で Top-1/Top-3/Top-5 を比較した。回避ペナルティを適用した条件では、Top-1/Top-3/Top-5 の全てで改善し、回避傾向が推薦結果に反映されることが確認できた。

順位	パターン	ステップ	Top-5（無）	Top-5（有）	差分	Top-5（time_auto）	差分	Top-5（有+time_auto）	差分
1	職種重視	40	51.2%	68.8%	+17.50%	57.5%	+6.25%	68.8%	+17.50%
2	勤務時間重視	40	52.5%	68.8%	+16.25%	61.3%	+8.75%	68.8%	+16.25%
3	時給重視	40	55.0%	67.5%	+12.50%	65.0%	+10.00%	68.8%	+13.75%
4	介護・施設重視	40	50.0%	66.3%	+16.25%	60.0%	+10.00%	66.3%	+16.25%
5	均等	40	55.0%	66.3%	+11.25%	65.0%	+10.00%	68.8%	+13.75%
6	業務内容重視	40	56.3%	66.3%	+10.00%	62.5%	+6.25%	67.5%	+11.25%

図 7.1: 18 名データの重み付けパターン比較（概観）

表 7.1: 回避ペナルティ有無の平均精度 (18 名, equal / 時間重み付け無し / 学習 20 件)

条件	Top-1	Top-3	Top-5
ペナルティ無し	0.478	0.628	0.694
ペナルティ有り	0.583	0.744	0.806
差分	+0.106	+0.117	+0.111

結果の解釈

改善幅は Top-3/Top-5 で特に大きく、回避ペナルティにより「候補の中身が良くなる (選びやすい候補が残る)」方向に働いたと解釈できる。これは、意味的類似度や条件一致で上位に来ていた求人の中から、回避項目を含むものが順位を下げ、相対的に応募しやすい求人が上位へ移動したためである。

考察と限界

回避業務ペナルティは、ユーザースタディで確認された「避けたい業務」を点数に直接反映できる点で有効である。一方で、(i) タグ付与が不十分な求人 (該当なしが多い等) では推定が弱くなる、(ii) 回避傾向が弱いワーカーでは差分が小さい、(iii) 回避が強いが「例外的に応募したい」状況 (報酬が高い、近い等) もあり得る、といった限界もある。今後は、回避度の更新頻度、ペナルティ強度の個別最適化、タグ品質の改善 (入力支援や正規化) などが課題となる。

時間志向の分布 (時間重み自動判別の出力)

時間重み自動判別は、履歴 (過去に選ばれた求人) が最近のものに偏っているべきか、あるいはある程度長い期間を均等に見たほうがよいかを、履歴の変化の大きさから推定し、内部的に時間重みパターンを切り替える。18 名の判定では、長期志向が 15 名、短期志向が 3 名であり、多くのワーカーは「好みの中心が大きくは変わっていない」と推定された。

7.2 追加実験 2: 時間志向を同時に扱った場合

目的

追加実験 2 では、回避業務ペナルティと、履歴の新しさを考慮する時間重み自動判別を同時に適用したときの挙動を確認する。回避は「仕事内容の好み (避けたい業務)」、時間重みは「好みの変化 (最近の履歴を重視すべきか)」に関わるため、両者を同時に入れると互いに強め合う場合もあれば、過剰に絞り込んでしまう場合もあり得る。そこで、同時適用が現実的に有効かを評価する。

実装方針と GUI 連携

GUI では「ペナルティ有無 + 時間重み自動判別 比較」を用意し、**ペナルティ無し/有り**に加えて**時間重み自動判別とペナルティ有り + 時間重み自動判別**を同時に評価できる。

長期志向/短期志向の判定（概要）

時間重み自動判別は、履歴の「好みの中心」が時間とともにどれだけ移動するかを見て、時間重みを切り替える。ここで「中心」とは、求人文を数値にしたベクトル（文章の意味を表す数値列）を平均したものとして扱う。

- 本研究のデータでは履歴に日付が含まれるため、日付ベースの候補（直近重視の指数減衰、期間制限型）から選択する（期間制限型は直近 90 日以内を同一重み、それ以前は重み 0）。
- 履歴が十分（8 件以上）ある場合、最近ウィンドウ（`recent_window = min(5, max(2, n/3))`）とそれ以前の中心を比較し、**ドリフト（好みの変化量）**を $1 - \text{cosine}(\text{recent_center}, \text{older_center})$ として算出する。ドリフトが 0.12 未満なら長期志向（好みが変わっていない）と判定し、期間制限型へ切り替える。

この判定情報（ラベル、採用パターン、ドリフト、ウィンドウ長）は結果表示に含め、同じワーカーでも「なぜ最近重視になったか/ならなかったか」を追跡できるようにした。

時間重みパターンの定義（直近重視の指数減衰 / 期間制限型）

時間重みは、履歴中の各求人に対して「現在（評価時点）からどれだけ過去か」を表す**経過日数**に基づいて計算し、履歴求人の埋め込み（意味ベクトル）の**重み付き平均**としてユーザープロファイルを作るために用いる。実装では、履歴内で最も新しい日付を基準日とし、各履歴求人の経過日数（`age_days`）を「基準日 - 当該求人の日付」の日数で定義する。

- 直近重視の指数減衰：新しい履歴ほど強く重視する方式であり、重みを $w = (0.5)^{\text{age_days}/7}$ とする（半減期 7 日）。
- 期間制限型：直近 90 日間の履歴のみを重み 1、それより古い履歴を重み 0 として扱う（ $\text{age_days} \leq 90$ なら $w = 1$ 、それ以外は $w = 0$ ）。

評価視点

回避ペナルティが有効であることを確認した上で、**時間志向（長期/短期）の自動判別**を同時に適用した場合の影響を確認する。




図 7.2: ペナルティ有無 + 時間重み自動判別の同時評価結果

結果（4 条件の同時比較）

同時比較では、(A) ペナルティ無し、(B) ペナルティ有り、(C) 時間重み自動判別、(D) 時間重み自動判別 + ペナルティ有りの 4 条件を、同じワーカー・同じ手順で評価した。10 名データでは、(D) が Top-1/Top-3/Top-5 で最も高い平均値となり、時間重み自動判別と回避ペナルティが競合せず補完的に働くケースが多いことを示した。

表 7.2: 4 条件同時比較の平均精度（学習 20 件, 18 名, equal）

条件	Top-1	Top-3	Top-5
(A) ペナルティ無し	0.478	0.628	0.694
(B) ペナルティ有り	0.583	0.744	0.806
(C) 時間重み自動判別	0.494	0.650	0.706
(D) 時間重み自動判別 + ペナルティ有り	0.567	0.750	0.794

表 7.3: 4 条件同時比較の平均精度（学習 15 件, 18 名, equal）

条件	Top-1	Top-3	Top-5
(A) ペナルティ無し	0.517	0.600	0.678
(B) ペナルティ有り	0.600	0.717	0.789
(C) 時間重み自動判別	0.517	0.611	0.694
(D) 時間重み自動判別 + ペナルティ有り	0.611	0.717	0.783

結果と考察

図 7.2 に示す通り、回避ペナルティの有無と時間重み自動判別の選択結果を同時に可視化することで、長期志向/短期志向の違いと上位候補の入れ替わりを把握できるように

なった。個別ワーカーでは、ペナルティ付与により「避けたい業務」を含む求人が上位から外れるケースが見られ、時間重み自動判別を併用した場合にも同様の傾向が確認された。

一方で、平均精度の増減はワーカーの履歴量や回避傾向の強さに依存する。今後は**回避度の更新頻度**や**ペナルティ強度の個別最適化**（例：回避が強い人ほど w を上げる、回避が弱い人は w を下げる）を検討する必要がある。また、回避項目の推定は「候補に出たのに選ばれない」を根拠にするため、候補生成の偏り（特定タグが候補に出にくい等）がある場合には推定が難しくなる。実運用で導入する際は、候補生成・表示・選択のログ設計も含め、推定が安定するデータ収集が重要である。

第 8 章

今後の展望

本研究では、応募履歴にもとづく重み付け・時間的重み付け（第 5 章）、ユーザスタディ（第 6 章）、回避業務ペナルティ（第 7 章）を通じて、推薦精度と意思決定要因の統合可能性を示した。一方で、実用的な推薦システムとして確立するためには、実運用に近い条件での検証と、ユーザー行動に基づく継続的な改善が必要である。今後の展望を以下に示す。

1. **ユーザスタディの拡大**：本研究ではインタビューを 2 件実施し、少数ながらも「リピート志向の強さ」や「駐車場・特定業務の優先度」など、推薦設計に直結する知見を得た。今後は対象者数を増やし、経験年数・勤務地域・移動手段・就業形態などの属性差を含めて、より多様な定性的視座を収集する。加えて、インタビュー結果と閲覧・応募ログを突き合わせることで、発話と行動の乖離も含めた要因整理を行う。
2. **リアルタイムフィードバックの実装と評価**：推薦結果に対する暗黙的フィードバック（閲覧時間、クリック、保存、スキップ等）を利用し、履歴にもとづくスコアに対してサービス上から重みを更新する仕組みを実装する。これにより、応募に至る前段階の関心も反映した重み付けが可能となる。複数の行動指標を組み込んだうえで重みの再推定を行い、Top- k 精度に加えて、閲覧から応募までの転換率なども含めて効果を評価する。
3. **実システム実装によるマッチング数の変移の検証**：提案手法を実サービスに組み込み、推薦表示がユーザー行動に与える影響を検証する。具体的には、A/B テスト等により応募数・マッチング成立数・リピート率・閲覧から応募までの所要時間などの指標を比較し、本実験で得られた改善が実運用でも再現されるかを確認する。あわせて、推薦導入により行動が変化した場合（探索が増える/固定化する等）のパターンを分析し、継続的な運用改善につなげる。

第9章

結論

本研究では、介護マッチングにおける意味的類似性の導入と複数項目を組み合わせた重み付けが、実務的に有用なマッチング精度を達成し得ることを示した。予備実験では日本語 Sentence-BERT が高い分離度を示し、職種・業務内容の意味的距離を捉える上で標準モデルとして有効であることを確認した。

本実験では、学習データ量や重み付けパターンにより精度が変動し、特に 15 件～20 件程度の学習データで良好な結果が得られた。これにより、履歴の長さを固定的に扱うのではなく、時間的重み付けを用いて嗜好の変化を反映することの重要性が明らかになった。時間重み付け比較では短期重視の減衰が安定して高い精度を示し、履歴のドリフトを考慮した自動選択も均等重みより改善効果があることを確認した。

さらに、ユーザスタディの知見を踏まえた回避業務ペナルティの検証では、Top-1/3/5 の改善が確認され、実務的な意思決定要因（避けたい業務）をスコアに組み込む有効性を示した。これは、単なる意味的類似性だけでなく、現場の判断基準を統合することが推薦品質に直結することを示唆する。

以上より、本研究は「意味的類似性」「行動履歴」「時間的重み付け」「業務回避ペナルティ」を統合したマッチング評価の枠組みを構築し、実データ上でその有効性を示した。これにより、ワーカーの希望により適合した求人を効率的に提示できるシステム基盤が整備されたといえる。

一方で、評価データ規模や入力品質のばらつき、回避傾向の推定精度などは依然として課題であり、実サービスへの導入には継続的な改善が必要である。今後は、実運用での A/B テストを通じた効果検証、UI 設計、非テキスト情報の取得と統合、そして運用ルールの整備を進めることで、実用的かつ持続可能なマッチングシステムの確立を目指す。

謝辞

本研究ならびに本論文の執筆にあたり、多大なるご指導・ご討論を賜りました北海道大学大学院情報科学研究院メディアネットワーク部門 土橋宜典教授に、心より感謝申し上げます。

また、本研究に際しご助言・ご協力を賜りました北海道大学大学院情報科学研究科メディアネットワーク専攻情報メディア学講座情報メディア環境学研究室の皆様、心より御礼申し上げます。

参考文献

- [1] 厚生労働省, ” 介護人材確保の現状について” 厚生労働省 (令和 7 年 5 月 9 日).
<https://www.mhlw.go.jp/content/12000000/001485589.pdf>
- [2] 厚生労働省, ” 福祉・介護人材確保対策について” 厚生労働省 (n.d.).
<https://www.mhlw.go.jp/seisaku/09.html>
- [3] 厚生労働省, ” 福祉人材確保対策” 厚生労働省 (n.d.).
https://www.mhlw.go.jp/stf/seisakunitsuite/bunya/hukushi_kaigo/seikat-suhogo/fukusijinzhai/index.html
- [4] 厚生労働省, ” 介護福祉士の資格等取得者の届出制度” 厚生労働省 (n.d.).
<https://www.mhlw.go.jp/stf/seisakunitsuite/bunya/0000158837.html>
- [5] 厚生労働省, ” 介護人材確保に向けた取組について” 厚生労働省 (n.d.).
https://www.mhlw.go.jp/stf/newpage_02977.html

研究業績

- [1] 星子 祐哉, 青木 直史, 土橋 宜典 “VGG16 の転移学習を利用した病的音声の検出”, 電気・情報関係学会北海道支部連合大会, オンライン開催, November 5-6, 2022.
- [2] 介護マッチングサービスにおけるマッチング精度向上の提案と実装 (星子 祐哉, 土橋 宜典), 令和 7 年度 電気・情報関係学会北海道支部連合大会 (2025/11/2 - 3).

付録 A

重み付けパターン一覧（本実験 1～4）

本付録では、本文の本実験で用いた重み付けパターンの一覧を示す。前半は**項目別重み付け**（職種・業務内容などの配分）、後半は**時間重み付け**（履歴の新しさを反映）である。

表 A.1: 項目別重み付けパターン一覧（全体）

パターン ID	GUI 表示名	重み	意図
equal	均等	1/1/1/1/1/1/1	全項目を同一比率で扱う基準。
content_focused	業務内容重視	1/3/1/1/1/1/1	業務内容の意味一致を強調。
salary_focused	時給重視	1/1/1/1/1/3/1	報酬条件を優先。
job_title_focused	職種重視	3/1/1/1/1/1/1	職種名の一致を重視。
care_focused	介護・施設重視	1/1/2/2/1/1/1	介護項目と施設種別を優先。
work_time_focused	勤務時間重視	1/1/1/1/3/1/1	勤務時間の条件一致を強調。
extreme_salary	極度時給重視	1/1/1/1/1/5/1	時給のみを極端に強調。
content_salary	業務内容 × 時給	1/3/1/1/1/3/1	業務内容と報酬を同時に強化。
content_salary_strong	業務内容 × 時給強化	1/4/1/1/1/4/1	業務内容と時給をさらに強調。
content_care_salary	業務 × 介護 × 時給	1/3/2/2/1/2/1	仕事内容と介護要素と報酬のバランス。
comprehensive	総合重視	1/3/2/2/2/3/1	内容・介護・条件を幅広く強化。
comprehensive_strong	総合重視強化	2/4/2/2/2/4/1	総合重視の強化版。
conditions_focused	勤務条件重視	1/1/1/1/3/3/1	勤務時間と時給に集中。
salary_time_strong	時給 × 勤務時間強化	1/1/1/1/4/4/1	条件重視をさらに強化。
balanced_high	高バランス	2/2/1/1/1/2/1	主要 3 項目を均等に強化。
content_dominant_balanced	業務主導バランス	2/4/1/1/1/2/1	業務内容を軸にバランス配分。
extreme_content	極端業務内容	1/5/1/1/1/1/1	業務内容を大きく強調。
ultra_content	超強力業務内容	1/7/1/1/1/1/1	業務内容への依存度をさらに高める。
mega_content	メガ業務内容	1/10/1/1/1/1/1	業務内容を最重要視する極端設定。
mega_content_salary	メガ業務 × 時給	1/8/1/1/1/5/1	業務内容と時給を極端に強化。
practical_focus	実務重視	1/3/3/3/1/1/1	現場実務に関わる要素を強化。
content_care_strong	業務 × 介護強化	1/4/3/3/1/1/1	業務内容と介護要素を強調。
content_care_avoidance	避ける業務考慮	1/5/5/1/1/1/1	避けたい業務の影響を反映。
care_items_dominant	介護項目極端重視	1/2/8/1/1/1/1	介護項目の有無を最重視。
content_care_balanced	業務 × 介護バランス	1/4/4/2/1/2/1	業務内容と介護項目のバランス。
task_detail_focused	タスク詳細重視	0/6/6/0/0/0/0	業務内容と介護項目のみで評価。
avoidance_optimized	避ける業務最適化	1/4/4/3/1/2/1	業務・介護・施設をバランス強化。
care_items_salary	介護項目 × 時給	1/2/5/1/1/4/1	介護項目と報酬のバランス。
ultra_care_items	超介護項目重視	1/1/10/1/1/1/1	介護項目を最優先に扱う。

本論文中で言及する主要な時間重み付けの代表例を示す。

表 A.2: 時間重み付けパターン（代表例）

パターン	意味
time_equal	時間減衰なし（全履歴を同一重み）。
time_recent_exp_7d	直近ほど重視する指数減衰（半減期 7 日）。
time_recent_linear_30d	直近ほど重視する線形減衰（30 日で 0）。
time_softmax_7d	直近ほど重視するソフトマックス型（温度 7 日相当）。
time_window_uniform_90d	直近 90 日を同一重み（それより古い履歴は 0）。
time_session_linear_10	セッション順の線形減衰（直近 10 件で 0）。
time_session_linear_20	セッション順の線形減衰（直近 20 件で 0）。

表 A.3: 時間重み付けパターン一覧（1/2）

パターン	意味
time_equal	時間減衰なし（全履歴を同一重み）。
time_recent_exp_7d	指数減衰（半減期 7 日）。
time_recent_exp_30d	指数減衰（半減期 30 日）。
time_recent_exp_90d	指数減衰（半減期 90 日）。
time_session_exp_5	セッション指数減衰（半減期 5 件）。
time_session_exp_10	セッション指数減衰（半減期 10 件）。
time_session_exp_20	セッション指数減衰（半減期 20 件）。
time_recent_linear_30d	線形減衰（30 日で 0）。
time_recent_linear_90d	線形減衰（90 日で 0）。
time_session_linear_10	セッション線形減衰（10 件で 0）。
time_session_linear_20	セッション線形減衰（20 件で 0）。
time_step_k_5	ステップ関数（直近 5 件のみ 1、それ以外 0）。
time_step_k_10	ステップ関数（直近 10 件のみ 1、それ以外 0）。
time_step_k_20	ステップ関数（直近 20 件のみ 1、それ以外 0）。
time_session_step_k_5	セッション順のステップ関数（直近 5 件のみ 1、それ以外 0）。
time_session_step_k_10	セッション順のステップ関数（直近 10 件のみ 1、それ以外 0）。
time_session_step_k_20	セッション順のステップ関数（直近 20 件のみ 1、それ以外 0）。
time_bi_level_5	2 段階重み（直近 5 件=1、以降=0.2）。
time_bi_level_10	2 段階重み（直近 10 件=1、以降=0.2）。
time_bi_level_20	2 段階重み（直近 20 件=1、以降=0.2）。
time_session_bi_level_5	セッション順の 2 段階重み（直近 5 件=1、以降=0.2）。
time_session_bi_level_10	セッション順の 2 段階重み（直近 10 件=1、以降=0.2）。
time_session_bi_level_20	セッション順の 2 段階重み（直近 20 件=1、以降=0.2）。

表 A.4: 時間重み付けパターン一覧（2/2）

パターン	意味
time_window_uniform_30d	30 日以内のみ 1、それ以前は 0。
time_window_uniform_90d	90 日以内のみ 1、それ以前は 0。
time_recent_power_1	パワー減衰 ($1/(age + 1)$)。
time_recent_power_2	パワー減衰 ($1/(age + 1)^2$)。
time_recent_log	対数減衰 ($1/\log(age + e)$)。
time_inverse_age_1	反比例減衰 ($1/(age + 1)$)。
time_sigmoid_30d_10d	シグモイド減衰（中心 30 日、幅 10 日）。
time_decay_then_flat_30d	30 日までは指数減衰、それ以降は 0.2 固定。
time_softmax_30d	ソフトマックス減衰（温度 30 日）。
time_softmax_7d	ソフトマックス減衰（温度 7 日）。
time_session_power_1	セッションパワー減衰 ($1/(k + 1)$)。

付録 B

システム構成概要（ディレクトリベース）

本研究で扱ったプロダクト群のコードベース構成を、リポジトリ直下の主要ディレクトリ単位で整理する。

- **care-provider-fe**: Angular を用いた介護事業者向けフロントエンド。求人作成、勤怠確認、設定管理などを担う。
- **care-worker-fe**: Flutter 製のワーカー向けクライアント。求人検索、応募、勤怠の打刻、ウォレット閲覧などを提供する。
- **kaigo-admin-fe**: 管理者向け Angular フロントエンド。事業所・求人・ユーザ管理や設定変更を行う。
- **kaigo-be**: Node.js/TypeScript ベースのバックエンド API。src/controllers, services, models を中心に、認証、求人・応募管理、勤怠計算、支払い処理などを実装している。
- **kaigo-payment-be**: 決済・外部送金系のバックエンド (Node.js/TypeScript)。七銀連携や決済ロジックを分離している。
- **pdf-generator**: PDF 生成用の専用サービス (Node.js)。通知書や帳票を生成する。
- **cron-jobs**: シェルスクリプトによる定期実行タスク群 (例: 日次・月次バッチ)。
- **documents**: 設計メモやドキュメント類 (システム構成、課題整理など)。
- **analyze_real_data**: 実データ分析・推薦評価の実験環境。Sentence-BERT を用いた推薦エンジンと評価器、職種ベース/介護項目ベースの軽量ベースライン、インタビュー知見を統合したハイブリッド推薦、FastAPI による Web GUI、単一分析/バッチ分析スクリプト、可視化・結果出力機能などを実装している。
- **master_thesis**: 本論文のソース一式 (LaTeX)。

付録 C

本実験 3：時間重み付け比較（特徴量配分別の詳細）

本文（本実験 3）では、議論を明確にするため特徴量配分を `equal` に固定した結果のみを示した。本付録では、**他の特徴量配分を含む**時間重み付け比較の結果をまとめる。

表 C.1: 時間重み付け比較（全特徴量配分平均, 複合スコア比較）

代表パターン	複合スコア	平均 Top-1	平均 Top-3	平均 Top-5	備考
直近重視の指数減衰	0.6199	0.5352	0.6880	0.7296	全重み付け平均で最良
直近 30 日線形減衰	0.6131	0.5278	0.6824	0.7222	線形に直近を重視
時間減衰なし	0.5734	0.4917	0.6278	0.6963	ベースライン

表 C.2: 時間重み付け上位パターン（学習 20 件, 全特徴量配分）

特徴量配分	時間重み	平均 Top-1	平均 Top-3	平均 Top-5
業務内容重視 (<code>content_focused</code>)	直近重視の指数減衰	0.5111	0.6889	0.7500
業務内容重視 (<code>content_focused</code>)	セッション順の線形減衰（短期）	0.5111	0.7000	0.7500
均等配分 (<code>equal</code>)	セッション順の線形減衰（中期）	0.5111	0.6333	0.7444

表 C.3: 時間重み付け上位パターン (学習 20 件, 全特徴量配分)

特徴量配分	時間重み	平均 Top-1	平均 Top-3	平均 Top-5
業務内容重視 (content_focused)	セッション順線形 10 件	0.5111	0.7000	0.7500
業務内容重視 (content_focused)	直近 7 日指数減衰	0.5111	0.6889	0.7500
均等配分 (equal)	セッション順線形 20 件	0.5111	0.6333	0.7444
業務内容重視 (content_focused)	Softmax 7 日	0.4778	0.6889	0.7444
業務内容重視 (content_focused)	直近 30 日線形減衰	0.5278	0.7000	0.7389
時給重視 (salary_focused)	セッション順線形 20 件	0.5167	0.6389	0.7389
勤務時間重視 (work_time_focused)	セッション順線形 20 件	0.5222	0.6222	0.7389
均等配分 (equal)	セッション順線形 10 件	0.5389	0.6667	0.7389
均等配分 (equal)	直近 7 日指数減衰	0.5556	0.6944	0.7389
均等配分 (equal)	直近 90 日線形減衰	0.5278	0.6611	0.7333
均等配分 (equal)	セッション順指数 (半減期 5)	0.5222	0.6611	0.7333
業務内容重視 (content_focused)	直近 5 件ステップ	0.5333	0.7056	0.7333
業務内容重視 (content_focused)	セッション順ステップ 5 件	0.5333	0.7056	0.7333
介護項目重視 (care_focused)	直近 7 日指数減衰	0.5500	0.6944	0.7333
勤務時間重視 (work_time_focused)	セッション順線形 10 件	0.5389	0.6611	0.7278
時給重視 (salary_focused)	直近 30 日指数減衰	0.5278	0.6556	0.7278
時給重視 (salary_focused)	セッション順指数 (半減期 10)	0.5056	0.6444	0.7278
業務内容重視 (content_focused)	直近 30 日指数減衰	0.5278	0.6667	0.7278
業務内容重視 (content_focused)	Softmax 30 日	0.5222	0.6667	0.7278
均等配分 (equal)	直近 30 日指数減衰	0.5389	0.6556	0.7278
均等配分 (equal)	2 段階重み (直近重視)	0.5000	0.6333	0.7278
均等配分 (equal)	セッション順の 2 段階重み (直近重視)	0.5000	0.6333	0.7278
勤務時間重視 (work_time_focused)	セッション順指数 (半減期 10)	0.5111	0.6278	0.7278
介護項目重視 (care_focused)	直近 30 日線形減衰	0.5389	0.6889	0.7278
均等配分 (equal)	直近 30 日線形減衰	0.5333	0.6722	0.7278
(参考) 直近 90 日ウィンドウの結果				
業務内容重視 (content_focused)	直近 90 日ウィンドウ	0.4944	0.6500	0.7167
均等配分 (equal)	直近 90 日ウィンドウ	0.4944	0.6500	0.7056
時給重視 (salary_focused)	直近 90 日ウィンドウ	0.4889	0.6500	0.7056
求人タイトル重視 (job_title_focused)	直近 90 日ウィンドウ	0.4278	0.6444	0.6889
介護項目重視 (care_focused)	直近 90 日ウィンドウ	0.5111	0.6556	0.6778
勤務時間重視 (work_time_focused)	直近 90 日ウィンドウ	0.5056	0.6556	0.6944

表 C.4: 時間重み付け上位パターン (学習 30 件, 全特徴量配分)

特徴量配分	時間重み	平均 Top-1	平均 Top-3	平均 Top-5
介護項目重視 (care_focused)	直近 30 日ウィンドウ	0.4182	0.5636	0.6909
勤務時間重視 (work_time_focused)	直近 5 件ステップ	0.4455	0.5727	0.6818
勤務時間重視 (work_time_focused)	セッション順ステップ 5 件	0.4455	0.5727	0.6818
介護項目重視 (care_focused)	直近 5 件ステップ	0.4364	0.5545	0.6818
介護項目重視 (care_focused)	セッション順ステップ 5 件	0.4364	0.5545	0.6818
時給重視 (salary_focused)	直近 30 日ウィンドウ	0.3455	0.5364	0.6818
業務内容重視 (content_focused)	直近 5 件ステップ	0.4455	0.6182	0.6727
業務内容重視 (content_focused)	セッション順ステップ 5 件	0.4455	0.6182	0.6727
勤務時間重視 (work_time_focused)	直近 30 日ウィンドウ	0.4545	0.5727	0.6727
求人タイトル重視 (job_title_focused)	直近 5 件ステップ	0.4273	0.5636	0.6636
求人タイトル重視 (job_title_focused)	セッション順ステップ 5 件	0.4273	0.5636	0.6636
均等配分 (equal)	直近 30 日ウィンドウ	0.3636	0.5364	0.6636
時給重視 (salary_focused)	直近 5 件ステップ	0.4091	0.5636	0.6545
時給重視 (salary_focused)	セッション順ステップ 5 件	0.4091	0.5636	0.6545
均等配分 (equal)	直近 5 件ステップ	0.4273	0.5545	0.6545
均等配分 (equal)	セッション順ステップ 5 件	0.4273	0.5545	0.6545
介護項目重視 (care_focused)	直近 30 日線形減衰	0.4182	0.5364	0.6545
業務内容重視 (content_focused)	S 字型減衰 (直近重視)	0.4182	0.5273	0.6545
均等配分 (equal)	直近 30 日線形減衰	0.4273	0.5273	0.6455
求人タイトル重視 (job_title_focused)	直近 30 日線形減衰	0.4091	0.5273	0.6455
時給重視 (salary_focused)	直近 30 日線形減衰	0.3909	0.5273	0.6455
業務内容重視 (content_focused)	直近 30 日ウィンドウ	0.4455	0.5455	0.6364
業務内容重視 (content_focused)	直近 30 日線形減衰	0.4000	0.5455	0.6364
求人タイトル重視 (job_title_focused)	Softmax 7 日	0.4091	0.5364	0.6364
求人タイトル重視 (job_title_focused)	直近 7 日指数減衰	0.4182	0.5273	0.6364
(参考) 直近 90 日ウィンドウの結果				
業務内容重視 (content_focused)	直近 90 日ウィンドウ	0.3818	0.4727	0.5455
均等配分 (equal)	直近 90 日ウィンドウ	0.3545	0.4636	0.5273
時給重視 (salary_focused)	直近 90 日ウィンドウ	0.3364	0.4636	0.5364
求人タイトル重視 (job_title_focused)	直近 90 日ウィンドウ	0.3818	0.4727	0.5364
介護項目重視 (care_focused)	直近 90 日ウィンドウ	0.3909	0.4727	0.5455
勤務時間重視 (work_time_focused)	直近 90 日ウィンドウ	0.3727	0.4727	0.5273

付録 D

基礎ベースライン（求人タイトルのみ・業務内容のみ）

本付録では、複数項目を統合した推薦手法（本文の本実験）に先立つ基礎検証として、求人タイトルのみおよび業務内容のみから応募履歴を学習した場合の推定精度を示す。

D.1 求人タイトルのみ

求人タイトル（職種名）のみを用い、過去応募履歴で出現したタイトルの出現頻度に基づいて候補求人を順位付けした。

表 D.1: ワーカー別の推薦精度（求人タイトルのみ、30 件学習、10 件テスト）

順位	ワーカー	Top-1	Top-3	Top-5	複合スコア
1	ワーカー A	100.0%	100.0%	100.0%	1.0000
2	ワーカー B	100.0%	100.0%	100.0%	1.0000
3	ワーカー C	60.0%	80.0%	80.0%	0.7000
4	ワーカー D	50.0%	80.0%	80.0%	0.6500
5	ワーカー E	60.0%	60.0%	60.0%	0.6000
6	ワーカー F	20.0%	80.0%	80.0%	0.5000
7	ワーカー G	20.0%	30.0%	40.0%	0.2700
8	ワーカー H	10.0%	30.0%	50.0%	0.2400
9	ワーカー I	10.0%	20.0%	30.0%	0.1700
10	ワーカー J	0.0%	30.0%	30.0%	0.1500
全体平均 (10 名)		43.0%	61.0%	65.0%	0.5280

表 D.2: 学習件数別の精度推移（求人タイトルのみ、18 名）

学習件数	n	平均 Top-1	平均 Top-3	平均 Top-5
10	20	0.4500	0.5000	0.5700
15	20	0.4600	0.6650	0.7050
20	17	0.6059	0.7765	0.8000
25	11	0.4909	0.6727	0.7273
30	10	0.4300	0.6100	0.6500
35	7	0.5429	0.7143	0.7714
40	5	0.5400	0.7000	0.7600

表 D.3: 就業回数上位 10 名を除いた場合の精度推移（求人タイトルのみ）

学習件数	n	平均 Top-1	平均 Top-3	平均 Top-5
10	10	0.5200	0.5600	0.6500
15	10	0.5000	0.7100	0.7300
20	7	0.7143	0.8143	0.8143
25	1	0.1000	0.4000	0.4000

D.2 業務内容のみ

業務内容テキストのみを用い、内容の近さに基づいて候補求人を順位付けした。

表 D.4: 学習件数別の精度推移（業務内容のみ、18 名）

学習件数	n	平均 Top-1	平均 Top-3	平均 Top-5
10	20	0.4350	0.4950	0.5650
15	20	0.3700	0.4450	0.5450
20	17	0.5412	0.6235	0.7294
25	11	0.4273	0.5182	0.6455
30	10	0.3000	0.4000	0.5200
35	7	0.2857	0.5286	0.5286
40	5	0.4800	0.5400	0.6000

表 D.5: 就業回数上位 10 名を除いた場合の精度推移（業務内容のみ）

学習件数	n	平均 Top-1	平均 Top-3	平均 Top-5
10	10	0.4300	0.4700	0.5600
15	10	0.3300	0.3700	0.4800
20	7	0.6571	0.7000	0.7286
25	1	0.1000	0.6000	0.7000

付録 E

本実験 4 補足：時間重み自動判別の詳細結果

本付録では、本実験 4（時間重み自動判別）に関して、本文から切り出した詳細結果を示す。

時間パターン別の優位性（18 名データ）

時間パターンの優位性をより俯瞰するため、**学習ステップ 20（履歴 20 件）**において、全重み付けパターン（6 種）における各時間パターンの平均 Top-K を集計した。その結果、**直近 7 日指数減衰**や **Softmax 7 日**、**セッション線形減衰**が上位に並び、短期の情報を重視する設計が安定して高い精度を示した（表 E.1）。これは本実験 3 の結論（古い履歴の混入が精度低下に繋がる）と整合的である。ただし、上位方式間の差は僅差であり、ワーカーごとの最適が分散する可能性も高い。このため、自動選択は「短期方式を常に採用する」ことではなく、**必要なときに短期へ寄せるためのスイッチ**として設計することが望ましい。

表 E.1: 18 名データの時間パターン上位（学習 20 件, 平均 Top-K, 全重み付け平均）

順位	時間パターン	平均 Top-1	平均 Top-3	平均 Top-5
1	直近 7 日指数減衰	0.5352	0.6880	0.7296
2	Softmax 7 日	0.5269	0.6778	0.7269
3	セッション順線形 10 件	0.5278	0.6731	0.7250
4	セッション順線形 20 件	0.5139	0.6324	0.7241
5	直近 30 日線形減衰	0.5278	0.6824	0.7222

また、equal のみで各ワーカーの最良パターンを確認すると、時間重み自動判別が 11 名、直近 7 日指数減衰が 3 名で最多となり、残りは他の減衰方式に分散した。これは**集団平均では短期重視が有利である一方、個別最適は多様である**ことを示している。

20 名データでの追試 (drift 閾値の影響)

本実験 4 の実装は、drift 閾値の設定により「安定（長期）」と「変化（短期）」の切替が変わる。そこで、20 名データ（うち 1 名はデータ読込エラーのため除外し、19 名で評価）に対して、drift 閾値を変えた複数条件で実行し、学習ステップ別の平均 Top-K を比較した。なお、学習ステップ 25 以降は履歴が不足するワーカーが増えるため、評価対象人数が減少する。

■drift 閾値 0.5 / 0.7 結果として、両設定で精度はほぼ一致し、時間重み自動判別は**全ワーカーが安定（長期）**判定となり、採用方式は**期間制限型（直近 90 日ウィンドウ）**に揃った。drift の分布は最小 0.005、最大 0.154（中央値 0.035）であり、いずれの閾値でも短期側へ切り替わらない範囲に収まっていた。学習ステップ別の平均 Top-K を表 E.2 に示す。

表 E.2: 20 名データにおける時間重み自動判別（equal）の学習ステップ別平均 Top-K（drift 閾値 0.5/0.7）

学習ステップ	対象人数	平均 Top-1	平均 Top-3	平均 Top-5
5	19	0.5316	0.6158	0.6947
10	19	0.4526	0.5526	0.6211
15	19	0.5105	0.6053	0.6895
20	19	0.4789	0.6316	0.7000
25	15	0.4733	0.5800	0.6333
30	11	0.3545	0.4636	0.5273
35	11	0.3455	0.5182	0.5455
40	8	0.4125	0.4750	0.6500

■drift 閾値 0.05 drift 閾値を 0.05 に設定すると、19 名のうち**安定（長期）が 11 名、直近（短期）が 8 名**となり、採用方式は**期間制限型（直近 90 日ウィンドウ）**と**直近 7 日指数減衰**に分かれた。学習ステップ別の平均 Top-K を表 E.3 に示す。

表 E.3: 20 名データにおける時間重み自動判別（equal）の学習ステップ別平均 Top-K（drift 閾値 0.05）

学習ステップ	対象人数	平均 Top-1	平均 Top-3	平均 Top-5
5	19	0.5316	0.6158	0.6947
10	19	0.4632	0.5474	0.6158
15	19	0.5053	0.6158	0.7000
20	19	0.4789	0.6316	0.7000
25	15	0.4733	0.5800	0.6333
30	11	0.3545	0.4636	0.5273
35	11	0.3455	0.5182	0.5455
40	8	0.3250	0.4750	0.6500

■drift 閾値 0.03 さらに drift 閾値を 0.03 に設定すると、**直近（短期）が 11 名、安定（長期）が 8 名**となり、短期側へ切り替わるワーカーが増加した。学習ステップ別の平均 Top-K を表 E.4 に示す。

表 E.4: 20 名データにおける時間重み自動判別 (equal) の学習ステップ別平均 Top-K
(drift 閾値 0.03)

学習ステップ	対象人数	平均 Top-1	平均 Top-3	平均 Top-5
5	19	0.5316	0.6158	0.6947
10	19	0.4632	0.5421	0.6263
15	19	0.5000	0.6526	0.7158
20	19	0.5211	0.6632	0.7316
25	15	0.4600	0.5800	0.6667
30	11	0.3545	0.4636	0.5273
35	11	0.3455	0.5000	0.5455
40	8	0.3250	0.4500	0.6375